

Topic-Modelle als qualitative Methode?

Sitzung 1 – Positionierung gegenüber
objektiver Hermeneutik und qualitativer Inhaltsanalyse

Prof. Dr. Christian Papilloud

Institut für Soziologie
Martin-Luther-Universität Halle-Wittenberg

Master Soziologie – 2026

Worum es in dieser Sitzung geht

Bevor wir zur praktischen Anwendung des Topic-Modell-Ansatzes mit dem Programm MTA (Multi-Text Analyser) kommen, beschäftigen wir uns in drei Sitzungen mit dem *theoretischen Hintergrund* von Topic-Modellen.

Drei Sitzungen, drei Fragen:

1. **Heute:** Ist Topic-Modellierung eine qualitative Methode? Wenn ja, in welchem Sinn? Wie verhält sie sich zu klassischen qualitativen Verfahren der Soziologie?
2. **Nächste Sitzung:** Wie funktionieren Topic-Modelle *mathematisch*? Was ist heute Stand der Technik (BERT, LLMs)?
3. **Dritte Sitzung:** Was können Topic-Modelle nicht, und welche Konsequenzen folgen daraus für unsere Forschungspraxis?

Eine erste, kontraintuitive These

Papilloud & Hinneburg (2018, S. 1)

„Topic-Modelle stellen ein quantitativ basiertes Werkzeug für die Textanalyse dar [...]. Topic-Modell-Verfahren sind zwar quantitativ basiert, aber sie *dienen der qualitativen Forschung* – eine Aussage, die nicht sofort einleuchten mag.“

Warum nicht? Weil das Begriffspaar „quantitativ vs. qualitativ“ meistens als Gegensatz verstanden wird:

- Statistik $\leftrightarrow$ Sinnverstehen
- Zahlen $\leftrightarrow$ Texte
- Erklären $\leftrightarrow$ Verstehen

Ein Verfahren, das Häufigkeiten zählt und Matrizen faktorisiert, klingt nicht nach hermeneutischer Arbeit. Und doch ...

Drei gemeinsame Grundannahmen

Objektive Hermeneutik, qualitative Inhaltsanalyse *und* Topic-Modell-Verfahren teilen drei Voraussetzungen:

1. Begriffe und Sätze werden **nicht zufällig** verwendet. Sinn ist nicht zufällig.
2. Texte enthalten **Strukturen**, die ihrem Sinn zugrunde liegen. Aufgabe der Analyse: diese Strukturen rekonstruieren.
3. Die **Deutung** – und damit der/die Forschende – spielt eine Rolle, sowohl bei der Organisation des Verfahrens als auch bei der Interpretation der Ergebnisse.

Vgl. Papilloud & Hinneburg 2018, S. 2–3.

Aber: drei Methoden, drei Antworten

Die gleichen Annahmen führen zu sehr unterschiedlichen Antworten auf drei Fragen:

- Was heißt „Struktur“ des Sinns?
→ *latente Sinnstruktur* (Oevermann) vs. *Kategoriensystem* (Mayring) vs. *topics* (Blei, Hinneburg)
- Wie wird „Sinn“ algorithmisch erzeugt?
→ universelle Grammatik (Chomsky) vs. Worthäufigkeiten und Konfigurationen
- Welche Rolle spielt der Forschende?
→ Gedankenexperiment vs. Codierung vs. Interpretation eines Klassifikationsmusters

Was uns interessiert: nicht die ganze Theorie

Die objektive Hermeneutik ist ein elaboriertes Forschungsprogramm. Wir konzentrieren uns auf drei Punkte, die für den *Kontrast* mit Topic-Modellen entscheidend sind:

1. Was ist **Lebenspraxis** und **objektive Sinnstruktur**?
2. Welches **methodologische Verfahren** folgt daraus?
3. Welche **Vorstellung von Sprache und Sinn** liegt zugrunde?

Quelle: Oevermann 1995, 1996, 2000, 2002, 2008, 2010. Vgl. Papilloud & Hinneburg 2018, Abschnitt 1.1.

Lebenspraxis und objektive Sinnstruktur

Bei Oevermann ist **Lebenspraxis** das Zusammenspiel physischer, psychischer, sozialer und kultureller Potentiale, die einem Einzelakteur die Gestaltung seines Lebens erlauben.

Zentrale Idee

Jede Lebenspraxis ist eine **Sequenz von Entscheidungen** – nicht eine Sequenz von Aussagen.

- Der Akteur steht ständig vor **Krisen**: Entscheidungssituationen ohne Richtig-/Falsch-Kalkulation.
- Er muss sich entscheiden – „er kann sich dem Prinzip nach nicht nicht entscheiden“.
- Die Begründung kommt *retrospektiv*: „widersprüchliche Einheit von Entscheidungszwang und Begründungsverpflichtung“.
- Die Verkettung dieser Entscheidungen bildet eine **objektive Sinnstruktur**.

Manifeste Sinnstruktur

Was der Akteur *explizit* sagt. Was im Protokoll dokumentiert ist. Beobachtbar.

Latente Sinnstruktur

Die *Verkettung* der Aussagen, das, was sich aus ihr *ergibt*. Nicht direkt beobachtbar. Muss vom Forschenden *gedeutet* werden.

Pointe

Die latente Sinnstruktur ist nicht das, was der Akteur *wirklich gemeint* hat. Sie ist die Struktur, die seinen Aussagen **vorausgeht** und sie ermöglicht – „regelerzeugter objektiver Sinn“ (Oevermann 2002).

Annahme: Es gibt eine *universelle generative Grammatik* (Chomsky), die Sinn algorithmisch erzeugt.

Schritte der Fallrekonstruktion:

1. Auswahl eines Protokolls (Transkript, Beobachtungsprotokoll usw.) bzw. eines *Falls*.
2. **Sequenzanalyse**: das Protokoll wird Schritt für Schritt durchgegangen. An jeder Sequenzstelle werden *Lesarten* entwickelt – alle möglichen Deutungen, die in diesem Kontext denkbar wären.
3. Schrittweise Eliminierung: nur die Lesarten überleben, die mit dem weiteren Verlauf des Protokolls vereinbar sind.
4. Ziel: die **Fallstrukturgesetzlichkeit** des beobachteten Falls rekonstruieren.

Ein arbeitsintensives Verfahren: stundenlange Interpretation einzelner Sätze, oft in Forschungsgruppen.

Mayrings Programm: ein hybrides Profil

Die qualitative Inhaltsanalyse (Mayring, seit Anfang der 1980er) möchte *nicht* im Gegensatz zur Quantifizierung stehen, sondern beide verbinden:

Mayring 2002, S. 114

„Texte systematisch analysieren, indem sie das Material schrittweise mit theoriegeleitet am Material entwickelten Kategoriensystemen bearbeitet.“

Kernoperation: das **Kategoriensystem**.

Bestandteile (Mayring 1994):

- Kategorien und Unterkategorien
- Kategoriendefinitionen
- Ankerbeispiele
- begründete Überarbeitung im Laufe der Auswertung

Was das Kategoriensystem leisten soll

Zwei Ansprüche, die sich *spannungsreich* ergänzen:

1. **Hermeneutische Tradition:** das Kategoriensystem soll den *manifesten und* den *latenten* Sinn der Textquelle abbilden.
2. **Quantitative Tradition:** das Kategoriensystem soll eine *systematische Überprüfung* von Strukturen erlauben (Reliabilität, Interkoderreliabilität, Triangulation).

Ziel

„Intersubjektiv nachvollziehbare Ergebnisse“: das, was eine Codiererin findet, soll auch eine zweite, unabhängige Codiererin finden können – Transparenz, Vergleichbarkeit.

Bekannte Kritik an Mayring

Die qualitative Inhaltsanalyse wird häufig kritisiert. Drei Punkte aus dem Buch (Papilloud & Hinneburg 2018, S. 11–12):

- Die Einbindung statistischer Methoden bleibt **rudimentär**: meistens auf Auszählung von Kategorienhäufigkeiten beschränkt.
- Kategorien werden zwar *induktiv* aus dem Text gewonnen, sind aber zunächst *deduktiv* angesetzt – der Bezug zum Text als Ganzem geht verloren (Plant 1996, Froggatt 2001, Lamnek & Krell 2005).
- Nach Kruse (2015): teilweise eine „rein quantifizierende Subsumtionslogik“. Mayring würde Äußerungen *inventarisieren*, aber nicht die Ebene der *latenten* Strukturen erreichen.

Wo Topic-Modelle stehen

Topic-Modelle teilen mit *beiden* Methoden die drei Grundannahmen vom Anfang. Aber sie unterscheiden sich von beiden in einem entscheidenden Punkt:

Was sich grundsätzlich ändert

Bei Oevermann und Mayring ist das *Kategoriensystem* (oder die Fallstruktur) das **Ergebnis menschlicher Interpretation**.

Bei Topic-Modellen ist es das **Ergebnis eines mathematischen Algorithmus** – der dann seinerseits interpretiert werden muss.

Was bedeutet das konkret?

Drei Unterschiede zur objektiven Hermeneutik

1. Begriff von „Algorithmus“.

Bei Oevermann: regelgeleitete Selektion in Möglichkeitswelten, universelle generative Grammatik.

Bei TM: statistische / linearealgebraische Verfahren – *die Grammatik ist nicht universell*, sondern verändert sich mit Gebrauch und Kontext.

2. Was wird gesucht?

Bei Oevermann: die *Fallstrukturgesetzlichkeit* eines bestimmten Falls.

Bei TM: *Klassifikationsmuster* über viele Dokumente hinweg.

3. Rolle der Kontextvariation.

Bei Oevermann: Gedankenexperimente, Lesarten – viele alternative Kontexte werden *aktiv* mobilisiert.

Bei TM: solche Variationen werden *bewusst vermieden* (Sinclair 1992): es zählen die typischen Merkmale des Textes.

Nähe zur qualitativen Inhaltsanalyse

Topic-Modelle stehen Mayring *näher* als Oevermann. Beide:

- bauen **Kategoriensysteme** aus dem Material auf,
- streben **Intersubjektivität** an (zweimal angewandt, zweimal vergleichbares Ergebnis),
- nutzen **Häufigkeiten** – aber für TM ist das nicht ein nachträglicher quantitativer Schritt, sondern die *Grundlage* der Kategorienbildung.

Wichtige Differenz

Was Mayring kritisiert wird (Kategorien bleiben oberflächlich, erreichen die latenten Strukturen nicht), versuchen TM methodisch zu vermeiden:

Sie nehmen die **Indexikalität der Sprache** ernst. Bedeutung ergibt sich aus der *Konfiguration* von Begriffen, nicht aus ihrer isolierten Codierung.

	Objektive tik	Hermeneu- tik	Qual. Inhaltsanalyse	Topic-Modell
Gegenstand	Einzelfall, biographische Sequenz		Textmaterial, Inventar von Aussagen	Textsammlung, Korpus
Algorithmus	generative Grammatik (Chomsky)		Kategoriensystem, manuelle Codierung	statistische / lineare Algebra
Sinnbegriff	latent, regelerzeugt, objektiv		manifest <i>und</i> latent	latent als Konfiguration von Begriffen
Forschende:r	deutet, Lesarten	entwickelt	codiert anhand des Systems	interpretiert das Klassifikationsmuster
Ergebnis	Fallstruktur-gesetzlichkeit		Kategorien mit Häufigkeiten	topics + Dokument-zugehörigkeiten
Korpusgröße	klein (1–20 Fälle)		mittel	groß (Hunderte bis Millionen)

Zwischenfazit der heutigen Sitzung

1. Die Frage „ist TM qualitativ?“ hat eine differenzierte Antwort: *ja*, im Sinne der drei Grundannahmen – *aber* mit einem mathematischen Algorithmus an der Stelle, wo bei klassischen Methoden ein interpretativer Akt steht.
2. TM ist **näher an Mayring als an Oevermann**. Es teilt das Ziel der Intersubjektivität und der Kategoriensysteme, geht aber methodisch anders vor.
3. Der *interpretative Akt* verschwindet *nicht* – er verschiebt sich nur. Bei TM geht es darum, das **Klassifikationsmuster** zu deuten, das der Algorithmus erzeugt hat. Dazu kommen wir in der dritten Sitzung zurück.

Sitzung 2 – Wie funktionieren Topic-Modelle?

- Was ist ein *topic* mathematisch? Die Idee der Matrixfaktorisierung anhand eines kleinen Beispiels.
- Vergleich mit Clusteranalyse und Faktorenanalyse.
- Die zwei Hauptverfahren: **LDA** (probabilistisch, bayessch) und **NMF** (lineare Algebra).
- *Neue Welt*: **BERTopic** und der Sprung zu *Embeddings*. Was bringen LLMs (GPT, Claude) in die Diskussion ein?
- Vorgriff auf die Frage, die uns durch die Praxis mit MTA begleiten wird: *warum* verwenden wir hier (noch) NMF und LDA – und nicht BERTopic oder einen LLM?

Eine Frage, die wir offen lassen

Zum Mitnehmen

Eine Sozialwissenschaftlerin, die mit MTA arbeitet, codiert nicht selbst, sondern sie *liest die Codierung* einer Maschine.

Verschiebt das die Subjektivität der Interpretation – oder verlagert es sie nur an einen anderen, weniger sichtbaren Ort?

Diese Frage werden wir in der dritten Sitzung wieder aufnehmen, wenn wir den Schlussblick des Buches (Kap. 8: *Rück- und Ausblick*) besprechen.

Zitierte Literatur (Auswahl) I

- **Papilloud, C., & Hinneburg, A.** (2018). *Einführung in die qualitative Analyse von Texten mit Topic-Modellen*. Wiesbaden: Springer.
Grundlage dieser Sitzung; bes. Kap. 1.
- Oevermann, U. (1995). Ein Modell der Struktur von Religiosität. In: M. Wohlrab-Sahr (Hrsg.), *Biographie und Religion*, 27–102. Frankfurt: Campus.
- Oevermann, U. (2002). *Klinische Soziologie auf der Basis der Methodologie objektiver Hermeneutik – Manifest*.
- Oevermann, U. (2008). *Krise und Routine als analytisches Paradigma in den Sozialwissenschaften* (Abschiedsvorlesung).
- Mayring, P. (1994). Qualitative Inhaltsanalyse. In: A. Boehm et al. (Hrsg.), *Texte verstehen*, 159–175. Konstanz: UVK.
- Mayring, P. (2002). *Einführung in die qualitative Sozialforschung*. Basel: Beltz.
- Kruse, J. (2015). *Qualitative Interviewforschung. Ein integrativer Ansatz*. Weinheim: Beltz.
- Przyborski, A., & Wohlrab-Sahr, M. (2009). *Qualitative Sozialforschung. Ein Arbeitsbuch*. München: Oldenbourg.

Zitierte Literatur (Auswahl) II

- Chomsky, N. (1981). *Regeln und Repräsentationen*. Frankfurt: Suhrkamp.
- Sinclair, J. (1992). The Automatic Analysis of Corpora. In: J. Svartvik (Hrsg.), *Directions in Corpus Linguistics*.

Vielen Dank.

Fragen, Einwände, Anschlüsse?

christian.papilloud@soziologie.uni-halle.de