

Wie funktionieren Topic-Modelle?

Sitzung 2 – Mathematische Grundlagen, LDA, NMF
und der Sprung zu BERT/LLMs

Begleitendes Handout

Prof. Dr. Christian Papilloud

Institut für Soziologie – Martin-Luther-Universität Halle-Wittenberg

Master Soziologie – 2026

1. Wo wir stehen

In der ersten Sitzung haben wir Topic-Modelle (TM) methodologisch positioniert: *quantitativ basiert*, aber im Dienst der qualitativen Forschung, näher an Mayrings qualitativer Inhaltsanalyse als an Oevermanns objektiver Hermeneutik. Heute fragen wir: *Wie funktioniert das technisch?* – vom kleinen Beispiel bis zu den neuesten Verfahren.

Dieses Handout folgt der gleichen Struktur wie die Sitzung:

1. Was ist ein *topic*? Die Matrixfaktorisierung anhand eines kleinen Beispiels.
2. Vergleich mit Clusteranalyse und Faktorenanalyse.
3. Die zwei klassischen Verfahren: LDA und NMF.
4. Die neue Welt: BERTopic und Large Language Models.

2. Was ist ein *topic*?

2.1 Die Intuition

Ein *topic* ist nichts Geheimnisvolles. Es ist eine **Wortliste** – eine Gruppe von Wörtern, die in den Dokumenten der untersuchten Textquelle *oft gemeinsam* vorkommen. Wenn die Wörter „Milch“ und „Katze“ immer wieder in denselben Dokumenten auftauchen, gibt es vermutlich ein *topic*, das beide enthält. Wenn ein drittes Wort, „Schale“, ebenfalls oft gemeinsam mit den ersten beiden auftaucht, gehört es ebenfalls dazu. So entsteht durch wiederholte Ko-Okkurrenz eine Wortgruppe, die wir als *semantisches Thema* interpretieren.

Ein Topic-Modell liefert immer zwei Resultate:

- Die **Topic-Wort-Zugehörigkeit**: für jedes *topic* eine Liste von Wörtern, jeweils mit einem *Gewicht*, das ausdrückt, wie zentral das Wort für dieses *topic* ist.

- Die **Topic-Gewichte der Dokumente**: für jedes Dokument eine Verteilung über die topics, die ausdrückt, in welchem Maße das Dokument zu welchem topic gehört.

In MTA werden wir diese beiden Resultate als CSV-Tabellen, JSON-Dateien und als Heatmap-Diagramme wiederfinden.

2.2 Das MLU-Sommer-Beispiel

Das Buch von Papilloud & Hinneburg (2018, Abb. 2.1) illustriert die Idee mit drei kleinen Dokumenten:

- *Dokument 1*: Die Studenten der MLU können die Teile des Campus im Sommer per Fahrrad erreichen.
- *Dokument 2*: Im Sommer gehen Menschen gern schwimmen oder fahren Fahrrad.
- *Dokument 3*: Die MLU bietet auf ihrem Campus den Studenten kostenlos Internet an.

Wir reduzieren die Texte auf ihre Substantive: *Campus*, *Fahrrad*, *Internet*, *Mensch*, *Sommer*, *Student*, *Teil*, *MLU*. Intuitiv erkennen Sie zwei Themenfelder: **Universität** (MLU, Campus, Student, Internet) und **Sommer** (Sommer, Fahrrad, Mensch).

Die zentrale Frage ist: Kann ein Algorithmus diese zwei Themen *ohne semantisches Vorwissen* finden? Die Antwort ist ja – und zwar durch eine mathematische Operation, die **Matrixfaktorisierung**.

2.3 Schritt 1: die Dokument-Wort-Matrix

Wir bauen eine Tabelle: jede Zeile ist ein Dokument, jede Spalte ein Wort. Der Eintrag in Zeile i , Spalte j ist die Häufigkeit, mit der Wort j in Dokument i vorkommt:

	Campus	Fahrrad	Internet	Mensch	Sommer	Student	Teil	MLU
Dok. 1	1	1	0	0	1	1	1	1
Dok. 2	0	1	0	1	1	0	0	0
Dok. 3	1	0	1	0	0	1	0	1

Diese **Dokument-Wort-Matrix** – nennen wir sie A – ist der Input jedes Topic-Modells. Bei einem realen Korpus von z.B. zehntausend Texten mit einem Vokabular von fünftausend Wörtern enthält sie 50 Millionen Einträge, von denen die allermeisten Nullen sind (kein einzelner Text enthält das gesamte Vokabular). Solche Matrizen heißen *sparse*.

2.4 Schritt 2: die Faktorisierung

Ein Topic-Modell zerlegt A in das *Produkt zweier kleinerer Matrizen*:

$$\underbrace{A}_{\text{Dokumente} \times \text{Wörter}} \approx \underbrace{W}_{\text{Dokumente} \times K} \cdot \underbrace{H}_{K \times \text{Wörter}}$$

wobei K die Anzahl der topics ist – ein Parameter, den wir vorher festlegen (im Beispiel: $K = 2$).

Was bedeuten W und H ? Die Matrix W sagt für jedes Dokument, wie stark es zu jedem topic

gehört (die *Topic-Gewichte*). Die Matrix H sagt für jedes topic, wie stark jedes Wort zu diesem topic gehört (der *Topic-Inhalt*).

Warum funktioniert das? Die Faktorisierung erzwingt eine *Datenkompression*: Statt 24 Einträge in A zu speichern, brauchen wir nur $3 \times 2 + 2 \times 8 = 22$ Einträge in W und H . Bei großen Matrizen ist die Reduktion enorm. Diese Kompression *zwingt* das Modell, die **wesentlichen Strukturen** der Daten zu finden – jene Strukturen, die sich „lohnen“, weil sie viele Dokumente und viele Wörter zugleich erklären.

Das Ergebnis im Beispiel:

Topic-Wort-Zugehörigkeit H :

	Campus	Fahrrad	Internet	Mensch	Sommer	Student	Teil	MLU
Topic 1 (<i>Uni</i>)	1	0	1	0	0	1	1	1
Topic 2 (<i>Sommer</i>)	0	1	0	1	1	0	0	0

Topic-Gewichte W : Dok. 1 enthält *beide* topics (Gewicht 1 und 1). Dok. 2 nur Sommer (0 und 1). Dok. 3 nur Uni (1 und 0). Der Algorithmus hat ohne semantisches Vorwissen die zwei Themenfelder gefunden, die wir intuitiv erkannt hatten.

2.5 Wie findet der Algorithmus die Zerlegung?

Das Problem ist *zirkulär*: Wenn man die topics kennt, kann man die Dokumente aufteilen; wenn man die Aufteilung kennt, kann man die topics bestimmen. Aber zu Beginn kennt man keines von beiden. Die Lösung ist die **iterative Annäherung**:

1. Man startet mit einer *zufälligen* Konfiguration der topics.
2. Man berechnet daraus die beste Dokumentaufteilung.
3. Man berechnet daraus wieder die besten topics.
4. Man wiederholt, bis sich nichts mehr ändert (Konvergenz).

Mit jeder Iteration verringert sich der *Rekonstruktionsfehler* – der Abstand zwischen der originalen Matrix A und ihrer Rekonstruktion $W \cdot H$. Weil dieser Fehler nach unten beschränkt ist (er kann nicht kleiner als 0 werden), konvergiert das Verfahren.

2.6 Eine wichtige Eigenschaft: die „Halluzinationen“

Wenn wir W und H multiplizieren, erhalten wir eine *rekonstruierte* Version der Dokument-Wort-Matrix. Diese Rekonstruktion ist nicht identisch mit dem Original.

Im Beispiel hatte Dok. 1 ursprünglich keinen Eintrag für die Wörter „Internet“ und „Mensch“. Die Rekonstruktion sagt aber: diese Wörter *passen* zu Dok. 1, denn dieses Dokument enthält die topics, zu denen sie gehören.

Diese „Halluzinationen“ sind kein Fehler. Sie sind einer der wichtigsten qualitativen Mehrwerte von Topic-Modellen: Sie machen *implizite* Bedeutungen sichtbar – semantische Nähe, die im Text *vorhanden*, aber nicht *explizit ausgesprochen* sind. Wenn ein Text über „Studenten“ und „Campus“ spricht, ohne „Internet“ zu erwähnen, sagt uns das Modell trotzdem, dass dieses Thema in der Nähe ist.

3. Vergleich mit Cluster- und Faktorenanalyse

3.1 Topic-Modelle vs. Clusteranalyse

Auf den ersten Blick wirken Topic-Modelle wie eine Spielart der Clusteranalyse. Beide bilden Gruppen von Objekten. Aber es gibt einen fundamentalen Unterschied:

- Eine Clusteranalyse (etwa K-Means) teilt Dokumente **disjunkt** ein: jedes Dokument gehört zu einem und nur einem Cluster. Das ist eine *harte* Klassifikation.
- Topic-Modelle sind **Mixed-Membership-Models** (Airoldi et al. 2014): Ein Dokument ist eine *Mischung* aus topics. Es kann zu 60 % aus Topic 1, zu 30 % aus Topic 2 und zu 10 % aus Topic 3 bestehen.

Dieser Unterschied ist nicht nur technisch. In der sozialwissenschaftlichen Praxis ist er entscheidend: Texte sind in aller Regel *thematisch heterogen*. Ein Interview enthält meistens mehrere Themen; ein wissenschaftlicher Artikel ebenso; eine Zeitungsausgabe sowieso. Eine harte Clustering würde dieser Heterogenität nicht gerecht.

Ein anschauliches Beispiel: Drei Gruppen von Dokumenten – nur über Sommer (Gruppe A), nur über die Universität (Gruppe B), über beides (Gruppe C). Eine Clusteranalyse fände *drei* Cluster: Sommer, Uni, Sommer+Uni. Die Kombination wird zu einem eigenen Cluster. Ein Topic-Modell findet *zwei* topics: Sommer und Uni. Die Gruppe C wird durch eine Mischung der beiden topics beschrieben.

Topic-Modelle finden also weniger, aber *interpretierbarere* Strukturen. Sie *zerlegen* die Komplexität in elementarere Themen, statt sie durch Kombinationen zu vervielfachen. Mathematisch ausgedrückt (Erosheva, Fienberg & Joutard 2007, später Galyardt 2014): Ein Topic-Modell mit K topics, das Dokumente mit insgesamt T Wörtern beschreibt, kann durch ein Cluster-Modell mit K^T Clustern *repräsentiert* werden. Die Mixed-Membership-Repräsentation ist also *viel* kompakter.

3.2 Topic-Modelle vs. Faktorenanalyse

Auch die Faktorenanalyse (FA) und die Hauptkomponentenanalyse (PCA) sind Matrixfaktorisierungen: $X \approx Z \cdot W^T$. Sie sehen strukturell wie Topic-Modelle aus. Es gibt aber zwei Unterschiede:

Erstens: die Vorzeichen. PCA und FA lassen *negative* Einträge in Z und W zu. Ein negativer Wert bedeutet semantisch: „dieses Wort soll *nicht* im Dokument vorkommen“. Solche „negativen topics“ sind für die qualitative Textanalyse kaum interpretierbar. Topic-Modelle wie NMF und

LDA verlangen, dass *alle Einträge* ≥ 0 sind. Diese Einschränkung macht die gefundenen topics zu *additiven Beiträgen*, die sich klar und eindeutig interpretieren lassen.

Zweitens: die Verteilungsannahmen. PCA setzt implizit eine *Normalverteilung* der Daten voraus. Worthäufigkeiten sind aber nicht normalverteilt: sie folgen Long-Tail-Verteilungen mit sehr vielen Nullen und einigen extrem häufigen Wörtern. Topic-Modelle wie LDA nutzen passendere Verteilungen (Multinomial, Dirichlet-Multinomial), die diese Eigenschaft besser abbilden.

4. Die zwei klassischen Verfahren: LDA und NMF

4.1 LDA – Latent Dirichlet Allocation

LDA (Blei, Ng & Jordan 2003) ist ein *probabilistisches* Topic-Modell. Es beschreibt die Erzeugung von Dokumenten als Zufallsprozess. Die Geschichte, die das Modell erzählt, klingt so:

1. Jedes topic ist eine *Wahrscheinlichkeitsverteilung über das Vokabular*. Wenn man dem topic eine Münze in die Hand gibt und sie würfeln lässt, kommt mit hoher Wahrscheinlichkeit ein Wort heraus, das zentral zum topic gehört – mit niedriger Wahrscheinlichkeit ein peripheres Wort. Parameter: φ_k für topic k .
2. Jedes Dokument hat ebenfalls eine *Verteilung über die topics*. Wenn man dem Dokument eine Münze in die Hand gibt, kommt mit hoher Wahrscheinlichkeit dasjenige topic, das dieses Dokument dominiert. Parameter: θ_d für Dokument d .
3. *Wie entsteht ein Wort im Dokument?* Für jedes Wort: würfle zuerst ein topic aus θ_d , dann würfle aus diesem topic ein Wort aus seiner Verteilung φ_k .

Das ist natürlich nicht, wie Menschen tatsächlich Texte schreiben. Es ist ein *generatives Modell*, das mathematisch gut zu handhaben ist. Die Berechnung kehrt das Modell um: gegeben die Wörter im Korpus, was sind die wahrscheinlichsten topics φ und Dokument-Verteilungen θ ?

Mathematisch sucht man die *Posterior-Verteilung* $p(\varphi, \theta, z \mid w)$. Sie ist nicht direkt berechenbar; es gibt zwei Approximationsverfahren: die **Variationsinferenz** (Blei et al. 2003) und das **Collapsed Gibbs Sampling** (Griffiths & Steyvers 2004). Was Sie sich merken sollten: *LDA liefert Wahrscheinlichkeiten, keine Punktwerte*.

4.2 NMF – Non-Negative Matrix Factorization

NMF (Lee & Seung 1999, 2001) löst dasselbe Problem ohne probabilistische Mathematik, rein durch lineare Algebra. Die Aufgabe ist ein Optimierungsproblem:

$$\min_{W, H \geq 0} \|A - W \cdot H\|_F$$

wobei $\|\cdot\|_F$ die *Frobenius-Norm* ist – eine Maßzahl, die misst, wie weit die rekonstruierte Matrix $W \cdot H$ vom Original A entfernt ist. Der Algorithmus, der diese Optimierung löst, heißt *Alternating Least Squares*: man hält W fest und optimiert H , dann hält man H fest und optimiert W , und so weiter, bis Konvergenz erreicht ist.

Im Gegensatz zu LDA hat NMF *keine* probabilistische Interpretation. Aber NMF ist meistens *schneller, deterministischer* (bei festem Startwert: identische Ergebnisse) und in vielen praktischen Situationen *stabiler*, besonders bei kleinen Korpora.

4.3 Wann LDA, wann NMF?

	LDA	NMF
Grundlage	Probabilistisches Modell	Lineare Algebra
Ausgabe	Wahrscheinlichkeiten	Gewichte (positiv)
Reproduzierbarkeit	Stochastisch, variiert je Lauf	Deterministisch bei festem Startwert
Geschwindigkeit	langsamer	schneller
Kleine Korpora	instabil	oft besser
Theoretische Eleganz	Bayessches Netzwerk	Optimierungsproblem

In MTA sind beide Verfahren implementiert. Eine empfehlenswerte Praxis ist, *beide laufen zu lassen* und ihre Ergebnisse zu vergleichen. Wenn LDA und NMF ähnliche topics liefern, ist das ein starkes Indiz für die Stabilität der gefundenen Strukturen. Wenn sie sehr unterschiedliche topics liefern, ist Vorsicht geboten – entweder die Topic-Anzahl ist falsch gewählt, oder das Korpus ist zu klein, oder die Vorverarbeitung muss verbessert werden.

4.4 Wie viele topics?

Sowohl LDA als auch NMF setzen die Anzahl K der topics als *externen Parameter* voraus. Diese Wahl ist nicht trivial; sie ist methodologisch und interpretativ.

Drei Strategien sind in der Literatur und in MTA verfügbar:

1. **Perplexity / Log-Likelihood** (für LDA): Wie gut beschreibt das Modell *neue* Daten, die nicht für das Training verwendet wurden? Theoretisch elegant, aber: nicht jedes topic, das die Perplexity verbessert, ist *interpretierbar* (Chang et al. 2009). Menschliche Bewertungen korrelieren manchmal sogar *negativ* mit Perplexity-Werten.
2. **Topic-Kohärenz** (PMI, Newman et al. 2010): Wie oft tauchen die top-Wörter eines topics nahe beieinander im Korpus auf? Diese Maßzahl korreliert besser mit menschlicher Bewertung. Verschiedene Varianten existieren (Röder, Both & Hinneburg 2015).
3. **Kreuzvalidierung mit Clusterverfahren** (in MTA implementiert): MTA berechnet eine Reihe von Indikatoren – Elbow, Silhouette, Calinski-Harabasz, Davies-Bouldin, Cophenet – und schlägt Ihnen einen Wertebereich für K vor.

Keine dieser Methoden liefert *die eine richtige Zahl*. Sie liefern einen *Wertebereich*, in dem die Entscheidung interpretativ getroffen werden muss. Die Frage „wie viele topics?“ ist immer auch eine *theoretische* Frage: Wie fein soll Ihre Themenstruktur sein? Was wollen Sie sehen?

5. Die neue Welt: BERTopic und LLMs

5.1 Ein methodologischer Sprung seit 2018

Das Buch von Papilloud & Hinneburg ist 2018 erschienen. Damals galten LDA und NMF als *state of the art*. Seitdem hat sich das Feld erheblich verändert. Vier Schritte:

- **2013 – Word2Vec** (Mikolov et al.): die Idee der *word embeddings*. Jedes Wort wird durch einen Vektor in einem hochdimensionalen Raum repräsentiert (typischerweise 100 bis 300 Dimensionen). Wörter mit ähnlicher Bedeutung haben *ähnliche* Vektoren. Die berühmte Gleichung $\vec{v}(\text{König}) - \vec{v}(\text{Mann}) + \vec{v}(\text{Frau}) \approx \vec{v}(\text{Königin})$ illustriert das Prinzip.
- **2018-2019 – BERT** (Devlin et al.): kontextuelle Embeddings. Dasselbe Wort hat verschiedene Vektoren je nach Satzkontext. „Bank“ in „Sitzbank im Park“ ist nicht „Bank“ in „Geld auf der Bank“.
- **2022 – BERTopic** (Grootendorst 2022): ein Topic-Modell, das BERT-Embeddings nutzt – der direkte „Nachfolger“ von LDA und NMF im Stand der Forschung.
- **2022 ff. – ChatGPT, GPT-4, Claude, LLaMA ...**: Large Language Models, die Texte direkt *verstehen* und *annotieren* können, ohne dass man ihnen eine Dokument-Wort-Matrix vorlegt.

5.2 Word2Vec, BERT und das Konzept der Embeddings

Embeddings sind die zentrale Neuerung, die alles, was danach kommt, ermöglicht. Die Grundidee: anstatt Wörter als *Symbole* zu behandeln („Hund“ ist einfach das fünfte Wort im Vokabular, mit Index 5), behandelt man sie als *Punkte in einem geometrischen Raum*. In diesem Raum gilt: semantisch ähnliche Wörter sind räumlich nahe.

Klassische Topic-Modelle (LDA, NMF) arbeiten mit *rohen* Worthäufigkeiten. Für sie sind die Wörter „König“ und „Königin“ unverbunden – sie sehen sich nur die Ko-Okkurrenz in Dokumenten an. Embeddings lösen dieses Problem: „König“ und „Königin“ haben ähnliche Vektoren, weil sie in ähnlichen Kontexten auftreten.

In MTA finden Sie diese Idee bereits in der Funktion *Semantic Context*: dort werden Word2Vec-ähnliche Embeddings (in der Standardform über Ko-Okkurrenz und PCA) genutzt, um semantische Nachbarn von Wörtern zu finden. Die Idee der Embeddings ist also keine ferne Zukunftsmusik – sie ist bereits Teil unserer Praxis.

5.3 BERTopic – ein moderner Topic-Modell-Workflow

BERTopic (Grootendorst 2022) bricht mit der Matrixfaktorisierung. Sein Workflow besteht aus vier Schritten:

1. Jedes Dokument wird durch **BERT** in einen hochdimensionalen Vektor verwandelt (typischerweise 768 Dimensionen).
2. Diese Vektoren werden durch **UMAP** auf wenige Dimensionen reduziert (Vorbereitung für das Clustering).
3. Die reduzierten Vektoren werden durch **HDBSCAN** geclustert. Jeder Cluster ist ein topic.
4. Für jeden Cluster wird die top-Wortliste durch eine angepasste TF-IDF-Heuristik berechnet (**c-TF-IDF**, class-based TF-IDF).

Statt eine Matrix zu faktorisieren, ordnet BERTopic also Dokumente einem Cluster zu – es ist eigentlich näher an einer Clusteranalyse als an einem klassischen Topic-Modell. Das macht es schnell und kontextsensitiv, hat aber Konsequenzen.

5.4 Empirische Vergleiche – die Forschungslage

Mehrere empirische Vergleiche der vergangenen Jahre haben LDA, NMF und BERTopic gegenübergestellt (Egger & Yu 2022; Kaur & Wallace 2024; Mishra 2026; Ma et al. 2025).

Wo BERTopic besser abschneidet:

- Bei *kurzen* Texten (Tweets, SMS, Antworten auf offene Fragen), wo Ko-Okkurrenz allein nicht ausreicht.
- In semantisch *nuancierten* Domänen, wo verschiedene Bedeutungen desselben Wortes wichtig sind.
- Höhere *Topic-Kohärenz* in vielen Benchmarks; auch qualitative Forschende präferieren oft BERTopic-Ergebnisse (Kaur & Wallace 2024 zeigen 67 % Präferenz für BERTopic in einer Studie mit 12 Forschenden).

Wo LDA und NMF kompetitiv bleiben:

- Bei *längeren* Texten (Artikeln, Interviews, Büchern), wo die Ko-Okkurrenz im Dokument reichlich Information liefert.
- Wenn *Interpretierbarkeit* und *Reproduzierbarkeit* wichtiger sind als marginale Kohärenz-Gewinne.
- Bei *kleinen* Korpora – BERTopic verlangt oft sehr viele Dokumente und verwirft regelmäßig 30 bis 70 % als „Outliers“ (Soledad et al. 2022).
- Bei *spezialisierten* Sprachen oder Disziplinen, für die kein guter vortrainierter BERT-Modell verfügbar ist (etwa historisches Deutsch, juristische Texte einer bestimmten Tradition, Korpora in selteneren Sprachen).

5.5 Large Language Models als analytische Werkzeuge

Seit 2022 verändert sich das Feld noch einmal. LLMs (GPT-4, Claude, LLaMA ...) bieten Möglichkeiten, die klassische TM nicht hatten:

- **Direkte Codierung von Texten** – inklusive deduktiver Codierung anhand eines Codebuchs (Tai et al. 2024).
- **Automatische Beschriftung** bestehender topics (TopicGPT, QualIT bei Amazon).
- **Reflexive Begleitung**: das LLM schreibt Memos, weist auf Widersprüche zwischen Codierungen hin, schlägt theoretische Rahmungen vor (Sinha et al. 2024).
- **Thematische Analyse von Interviews** ohne klassisches TM (De Paoli 2023).

Eine umfangreiche Literatur ist seit 2023 entstanden. Hayes (2025) und Than et al. (2025) bieten gute Überblicke aus soziologischer Sicht.

5.6 Eine empirische Warnung: Ashwin, Chhabra & Rao (2025)

Eine besonders wichtige Arbeit ist 2025 in den *Sociological Methods & Research* erschienen. Die Autoren untersuchten Interviews mit Rohingya-Geflüchteten und ihren bengalischen Gastgebern in Bangladesch. Sie verglichen die Codierung durch einen LLM mit der Codierung durch trainierte menschliche Codiererinnen.

Der zentrale Befund. Die LLM-Codierungen sind nicht nur *ungenau*, sondern **systematisch verzerrt**. Die Fehler des LLMs verteilen sich *nicht zufällig*, sondern korrelieren mit Merkmalen der Befragten – ihrer Sprache, ihrem Bildungsgrad, ihrer Herkunftsregion. Inferenzen, die auf solchen Codierungen beruhen, können in eine *bestimmte Richtung* systematisch falsch sein.

Die Konsequenz, die die Autoren ziehen: Es sei oft besser, ein *eigenes, kleineres* Modell auf hochwertigen, manuell codierten Daten zu trainieren als einen generischen LLM einzusetzen. Diese Empfehlung ist auch für die qualitative Sozialforschung relevant: Quantitative Effizienz darf nicht auf Kosten methodologischer Belastbarkeit gehen.

5.7 Warum bleibt MTA bei LDA und NMF?

Eine berechtigte Frage. Die Antwort hat vier Aspekte:

1. **Lokal, offline, autonom.** MTA läuft auf Ihrem Laptop ohne Internetverbindung und ohne API-Schlüssel. Ihre Forschungsdaten verlassen Ihre Maschine nicht. Das ist nicht nur eine Frage der Bequemlichkeit, sondern auch der *Forschungsethik* und des *Datenschutzes* – besonders bei sensiblen Daten (Interviews mit Geflüchteten, medizinische Texte, persönliche Korrespondenz).
2. **Interpretierbarkeit.** LDA und NMF liefern nachvollziehbare Wortlisten und Gewichte. Sie können einer Kollegin oder einer Gutachterin erklären, *warum* ein topic so aussieht, wie es aussieht. Bei BERTopic und LLMs ist die Kette zwischen Input und Output deutlich opaker.

3. **Reproduzierbarkeit.** NMF mit festem Startwert produziert *exakt dieselben* Ergebnisse, jedes Mal. LDA ist stochastisch, aber durch wiederholte Läufe lässt sich die Variabilität abschätzen. LLMs sind dagegen oft schlecht reproduzierbar – ihre Antworten hängen vom Modellzustand, von der *Temperature*, von kleinen Variationen im Prompt ab.
4. **Forschungsdidaktik.** Wer LDA und NMF verstanden hat, versteht den *Kern* der Topic-Modellierung – die Matrixfaktorisierung, das Mixed-Membership-Prinzip, die Logik der Ko-Okkurrenz. Wer mit BERTopic oder einem LLM anfängt, ohne Embeddings zu verstehen, arbeitet mit einer Blackbox. Diese Vorlesungen wollen Ihnen die Werkzeuge in die Hand geben, später *informiert* zwischen den Verfahren wählen zu können.

6. Fragen zum Mitnehmen

Drei Fragen, über die Sie bis zur nächsten Sitzung nachdenken können:

1. Wir haben gesehen, dass Topic-Modelle „Halluzinationen“ produzieren: sie schreiben einem Dokument Wörter zu, die es ursprünglich nicht enthielt. Wir haben diese Eigenschaft als *qualitativen Mehrwert* dargestellt. Unter welchen Bedingungen könnte sie umgekehrt zum *Problem* werden?
2. Ashwin et al. (2025) zeigen, dass LLMs systematisch verzerrte Codierungen produzieren. Können Sie sich Quellen *ähnlicher* Verzerrungen vorstellen, die auch bei LDA oder NMF auftreten könnten?
3. Die Wahl der Topic-Anzahl K ist immer auch eine *theoretische* Wahl. Wenn Sie Interviews mit Studierenden zum Thema „digitale Lehre“ analysieren würden, welche Theorien würden Ihre Wahl von K leiten?

7. Ausblick auf Sitzung 3

In der dritten und letzten theoretischen Sitzung wenden wir uns dem *Vorher* und *Nachher* des Algorithmus zu:

- *Vor* dem Algorithmus: die Vorverarbeitung der Textquelle (Bereinigung, Stoppwörter, TF-IDF, Lemmatisierung, Named Entity Recognition). Was MTA *tut* und was es *nicht* tut.
- Metadaten und Topic-Modelle: drei Strategien (Spaltung, Hinzufügung, Lernergänzung).
- *Nach* dem Algorithmus: der kritische Blick (Buch, Kap. 8). Was Topic-Modelle *nicht* können. Zwei verbreitete Erwartungen, die nicht erfüllt werden.
- Was sich für unsere Forschungspraxis ändert – und wie diese drei theoretischen Sitzungen in die folgende Arbeit mit MTA münden.

Zitierte Literatur

GRUNDLAGE:

Papilloud, C., & Hinneburg, A. (2018). *Einführung in die qualitative Analyse von Texten mit Topic-Modellen*. Wiesbaden: Springer. *Bes. Kap. 2 und 3.*

KLASSISCHE TOPIC-MODELLE UND MATRIXFAKTORISIERUNG:

Airoldi, E. M., Blei, D. M., Erosheva, E. A., & Fienberg, S. E. (Hrsg., 2014). *Handbook of Mixed Membership Models and Their Applications*. CRC Press.

Blei, D. M. (2012). Probabilistic Topic Models. *Communications of the ACM*, 55(4), 77–84.

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993–1022.

Chang, J., Boyd-Graber, J., Wang, C., Gerrish, S., & Blei, D. M. (2009). Reading Tea Leaves: How Humans Interpret Topic Models. *NIPS*.

Erosheva, E. A., Fienberg, S. E., & Joutard, C. (2007). Describing Disability Through Individual-Level Mixture Models for Multivariate Binary Data. *Annals of Applied Statistics*, 1(2), 502–537.

Griffiths, T. L., & Steyvers, M. (2004). Finding Scientific Topics. *PNAS*, 101(suppl. 1), 5228–5235.

Lee, D. D., & Seung, H. S. (2001). Algorithms for Non-Negative Matrix Factorization. In *Advances in Neural Information Processing Systems*.

Newman, D., Lau, J. H., Grieser, K., & Baldwin, T. (2010). Automatic Evaluation of Topic Coherence. *NAACL HLT*.

Röder, M., Both, A., & Hinneburg, A. (2015). Exploring the Space of Topic Coherence Measures. *WSDM*.

WORD EMBEDDINGS UND BERT:

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *NAACL HLT*.

Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., & Dean, J. (2013). Distributed Representations of Words and Phrases and their Compositionality. *NIPS*.

Mostafavi, M., Porter, M. D., & Robinson, D. T. (2025). Contextual Embeddings in Sociological Research: Expanding the Analysis of Sentiment and Social Dynamics. *Sociological Methodology*.

BERTOPIC UND VERGLEICHE:

Egger, R., & Yu, J. (2022). A Topic Modeling Comparison Between LDA, NMF, Top2Vec, and BERTopic to Demystify Twitter Posts. *Frontiers in Sociology*, 7.

Grootendorst, M. (2022). BERTopic: Neural Topic Modeling with a Class-Based TF-IDF Procedure. *arXiv:2203.05794*.

Kaur, A., & Wallace, J. R. (2024). Moving Beyond LDA: A Comparison of Unsupervised Topic Modelling Techniques for Qualitative Data Analysis of Online Communities. *arXiv:2412.14486*.

Ma, L., et al. (2025). AI-powered Topic Modeling: Comparing LDA and BERTopic in Analyzing Opioid-Related Cardiovascular Risks in Women. *Experimental Biology and Medicine*.

Mishra, M. (2026). Comparative Analysis of BERTopic Versus LDA: Topic Modelling in Marketing Research. *Asia-Pacific Journal of Management Research and Innovation*.

LARGE LANGUAGE MODELS IN DER QUALITATIVEN SOZIALFORSCHUNG:

Ashwin, J., Chhabra, A., & Rao, V. (2025). Using Large Language Models for Qualitative Analysis can Introduce Serious Bias. *Sociological Methods & Research*.

Bail, C. A. (2024). Can Generative AI Improve Social Science? *PNAS*, 121(21).

De Paoli, S. (2023). Performing an Inductive Thematic Analysis of Semi-Structured Interviews With a Large Language Model: An Exploration and Provocation on the Limits of the Approach. *Social Science Computer Review*.

Hayes, A. S. (2025). „Conversing“ With Qualitative Data: Enhancing Qualitative Research Through Large Language Models (LLMs). *International Journal of Qualitative Methods*.

Sinha, R., et al. (2024). Generative AI as a Reflexive Co-Researcher in Grounded Theory.

Tai, R. H., Bentley, L. R., Xia, X., et al. (2024). An Examination of the Use of Large Language Models to Aid Analysis of Textual Data. *International Journal of Qualitative Methods*.

Than, N., Fan, L., Law, T., Nelson, L. K., & McCall, L. (2025). Updating „The Future of Coding“: Qualitative Coding with Generative Large Language Models. *Sociological Methods & Research*.