

Wie funktionieren Topic-Modelle?

**Sitzung 2 – Mathematische Grundlagen,
LDA, NMF und der Sprung zu BERT/LLMs**

Prof. Dr. Christian Papilloud

Institut für Soziologie
Martin-Luther-Universität Halle-Wittenberg

Master Soziologie – 2026

Wo wir stehen

In der letzten Sitzung haben wir Topic-Modelle (TM) *methodologisch* positioniert: Sie sind *quantitativ basiert*, dienen aber der qualitativen Forschung – näher an Mayring als an Oevermann.

Heute fragen wir: **Wie funktioniert das technisch?**

Vier Blöcke:

1. Was ist ein *topic*? Die Matrixfaktorisierung anhand eines kleinen Beispiels („MLU/Sommer“).
2. Vergleich mit zwei verwandten Verfahren: *Clusteranalyse* und *Faktorenanalyse*.
3. Die zwei klassischen TM-Verfahren: **LDA** und **NMF**.
4. *Neue Welt*: **BERTopic** und **LLMs**. Was ändert sich? Warum bleibt MTA bei LDA/NMF?

Die zentrale Intuition

Definition (sehr informell)

Ein *topic* ist eine **Wortliste** – eine Gruppe von Wörtern, die *oft gemeinsam* in Dokumenten vorkommen.

Wenn „Milch“ und „Katze“ immer wieder gemeinsam auftauchen, gibt es vermutlich ein topic, das beide enthält.

Ein Topic-Modell liefert zwei Dinge:

- **Topic-Wort-Zugehörigkeit:** Welche Wörter bilden welches topic? (Mit welchem Gewicht?)
- **Topic-Gewichte der Dokumente:** Welche Dokumente enthalten welche topics? (In welchem Anteil?)

Diese beiden Ergebnisse sind das, was wir in MTA als CSV-Dateien und Heatmaps wiederfinden werden.

Beispiel: drei Dokumente, acht Wörter

Dokumente (Papilloud & Hinneburg 2018, Abb. 2.1):

Dok. 1	Die Studenten der MLU können die Teile des Campus im Sommer per Fahrrad erreichen.
Dok. 2	Im Sommer gehen Menschen gern schwimmen oder fahren Fahrrad.
Dok. 3	Die MLU bietet auf ihrem Campus den Studenten kostenlos Internet an.

Reduziert auf *Substantive*: Campus, Fahrrad, Internet, Mensch, Sommer, Student, Teil, MLU.

Inhaltlich erkennen wir intuitiv *zwei Themen*: **Universität** (MLU, Campus, Student, Internet) und **Sommer** (Sommer, Fahrrad, Mensch).

Die Frage: kann ein Algorithmus diese zwei Themen *ohne Vorwissen* finden? Die Antwort: ja, durch Matrixfaktorisierung.

Schritt 1: Dokument-Wort-Matrix A

Wir bauen eine Tabelle: Zeilen = Dokumente, Spalten = Wörter. Eintrag = wie oft kommt das Wort im Dokument vor?

	Campus	Fahrrad	Internet	Mensch	Sommer	Student	Teil	MLU
Dok. 1	1	1	0	0	1	1	1	1
Dok. 2	0	1	0	1	1	0	0	0
Dok. 3	1	0	1	0	0	1	0	1

Diese **Dokument-Wort-Matrix** A ist der Input jedes Topic-Modells. Bei einem realen Korpus von 10 000 Texten mit einem Vokabular von 5 000 Wörtern hat sie 50 Millionen Einträge – meistens Nullen (*sparse matrix*).

Schritt 2: Faktorisierung in zwei kleinere Matrizen

Ein Topic-Modell zerlegt A in das *Produkt* zweier *kleinerer Matrizen*:

$$\underbrace{A}_{\text{Dokumente} \times \text{Wörter}} \approx \underbrace{W}_{\text{Dokumente} \times K} \cdot \underbrace{H}_{K \times \text{Wörter}}$$

wobei K die Anzahl der topics ist (hier: $K = 2$).

Was bedeutet das?

- W sagt: *Welches topic in welchem Dokument?* (Topic-Gewichte)
- H sagt: *Welche Wörter in welchem topic?* (Topic-Inhalt)

Statt $3 \times 8 = 24$ Werte (in A) brauchen wir nur $3 \times 2 + 2 \times 8 = 22$ Werte (in W und H). Bei größeren Matrizen ist die Reduktion enorm – und sie zwingt das Modell, die *wesentlichen Strukturen* zu finden.

Ergebnis im Beispiel

Topic-Wort-Zugehörigkeit H – welche Wörter bilden welches topic:

	Campus	Fahrrad	Internet	Mensch	Sommer	Student	Teil	MLU
Topic 1 (<i>Uni</i>)	1	0	1	0	0	1	1	1
Topic 2 (<i>Sommer</i>)	0	1	0	1	1	0	0	0

Topic-Gewichte der Dokumente W :

	Topic 1	Topic 2
Dok. 1	1	1
Dok. 2	0	1
Dok. 3	1	0

Dok. 1 enthält *beide* topics. Dok. 2 nur Sommer. Dok. 3 nur Uni.

Wie findet der Algorithmus diese Zerlegung?

Das Problem ist *zirkulär*:

- Wenn man die topics kennt $\rightarrow$ kann man die Dokumente aufteilen.
- Wenn man die Aufteilung kennt $\rightarrow$ kann man die topics bestimmen.
- Aber man kennt am Anfang *keines* von beiden.

Lösung: **iterative Annäherung**.

1. Starte mit einer *Zufallskonfiguration* der topics.
2. Berechne daraus die beste Dokumentaufteilung.
3. Berechne daraus wieder die besten topics.
4. Wiederhole, bis sich nichts mehr ändert (Konvergenz).

Mit jeder Iteration verringert sich der „Rekonstruktionsfehler“ – der Unterschied zwischen A und $W \cdot H$.

Was wir aus der Faktorisierung zurückrekonstruieren

Wenn wir W und H multiplizieren, erhalten wir eine **rekonstruierte** Dokument-Wort-Matrix.

Vergleichen wir mit der originalen:

<i>Original:</i>								
Dok. 1		1	1	0	0	1	1	1
<i>Rekonstruktion:</i>								
Dok. 1		1	1	1	1	1	1	1

Beachten Sie: Dok. 1 enthielt *Internet* und *Mensch* ursprünglich nicht. Die Rekonstruktion sagt aber: diese Wörter *passen* zu Dok. 1, denn es enthält die topics, zu denen sie gehören.

Pointe für die qualitative Analyse

Diese „Halluzinationen“ sind oft **kein Fehler**: Sie machen *implizite* Bedeutungen sichtbar – semantische Nähen, die im Text vorhanden, aber nicht explizit ausgesprochen sind.

Ist das nicht einfach Clusteranalyse?

Auf den ersten Blick: ja. Beide Verfahren ordnen Objekte (Dokumente) in Gruppen ein.

Aber: K-Means & Co. teilen Dokumente **disjunkt** ein. Ein Dokument gehört zu *einem* Cluster und sonst zu keinem. Es ist eine *harte* Klassifikation.

Schlüsselunterschied

Topic-Modelle sind **Mixed-Membership-Models**:

Ein Dokument ist eine *Mischung* aus topics. Es kann zu 60 % aus Topic 1, zu 30 % aus Topic 2 und zu 10 % aus Topic 3 bestehen.

Das ist nicht nur eine technische Spitzfindigkeit. In der sozialwissenschaftlichen Praxis ist es *entscheidend*: Texte sind meistens *thematisch heterogen*, nicht monothematisch.

Drei Dokumente: Sommer, Uni, beides

Stellen Sie sich drei Gruppen von Dokumenten vor:

- Gruppe A: nur über Sommer
- Gruppe B: nur über die Universität
- Gruppe C: über *beides*

Was findet ein K-Means-Cluster?

→ *Drei* Cluster: Sommer, Uni, Sommer+Uni.

Die Kombination wird zu einem eigenen Cluster.

Was findet ein Topic-Modell?

→ *Zwei* topics: Sommer und Uni.

Die Gruppe C wird durch eine *Mischung* der beiden topics beschrieben.

Konsequenz

Topic-Modelle finden weniger, aber *interpretierbarere* Strukturen. Sie zerlegen die Komplexität, statt sie zu vervielfachen.

Was ist mit der Faktorenanalyse (PCA, FA)?

Auch die Faktorenanalyse ist eine Matrixfaktorisierung: $X \approx Z \cdot W^T$. Das sieht aus wie ein Topic-Modell.

Zwei wichtige Unterschiede:

- **Vorzeichen.** PCA & FA lassen *negative* Einträge zu. Negativ heißt: „dieses Wort soll *nicht* im Dokument vorkommen“.

Bei Topic-Modellen müssen alle Werte ≥ 0 sein. *Warum?* Negative Topics lassen sich qualitativ kaum interpretieren.

- **Verteilung der Daten.** PCA setzt *Normalverteilungen* voraus. Worthäufigkeiten sind *nicht* normalverteilt („long tail“, viele Nullen).

TM nutzen passendere Verteilungen (Multinomial, Dirichlet-Multinomial).

Synopse: drei Klassifikationsverfahren

	Clusteranalyse	Faktorenanalyse	Topic-Modell
Zuordnung	disjunkt (ein Cluster pro Objekt)	faktoriell, evtl. negativ	mixed-membership (Mischung)
Wertbereich	beliebig	$\mathbb{R}$ (auch negativ)	≥ 0
Verteilungsannahme	Gauß / Bernoulli	Gauß	Multinomial / Dirichlet
Anzahl Klassen	wächst bei Kombinationen	klein, oft schwer zu interpretieren	stabil, additiv interpretierbar
Geeignet für Texte?	wenn Texte monothematisch	nur eingeschränkt	ja, primärer Zweck

LDA – Latent Dirichlet Allocation

LDA (Blei, Ng & Jordan 2003) ist ein **probabilistisches** Topic-Modell. Es modelliert die Erzeugung von Dokumenten als Zufallsprozess.

Erzählung des Modells (frei):

1. Jedes *topic* ist eine Wahrscheinlichkeitsverteilung über das Vokabular (parametrisiert durch φ_k).
2. Jedes *Dokument* hat eine Verteilung über die topics (parametrisiert durch θ_d).
3. *Wie entsteht ein Wort?* Für jedes Wort im Dokument:
 - würfle ein topic aus θ_d ,
 - würfle ein Wort aus dem topic.

Das ist natürlich *nicht*, wie Menschen Texte schreiben. Es ist ein *generatives Modell*, das in der Mathematik gut zu handhaben ist.

LDA – die Berechnung in einem Satz

Wir *kehren das Modell um*: gegeben die Wörter im Korpus, was sind die wahrscheinlichsten topics und Topic-Verteilungen?

Mathematisch: Wir suchen die *Posterior-Verteilung* $p(\varphi, \theta, z \mid w)$. Sie ist nicht direkt berechenbar, deshalb gibt es zwei Approximationsverfahren:

- **Variationsinferenz** (Blei et al. 2003) – analytisch, sucht eine einfachere Verteilung in der Nähe der echten.
- **Collapsed Gibbs Sampling** (Griffiths & Steyvers 2004) – stichprobenartig, würfelt Wort-Topic-Zuordnungen neu, bis sich ein stabiles Bild ergibt.

Was Sie sich merken sollten: LDA ist eine *Bayessche Schätzung*. Sie liefert Wahrscheinlichkeiten, keine Punktwerte.

NMF – Non-Negative Matrix Factorization

NMF (Lee & Seung 2001) löst dasselbe Problem *ohne Statistik*: rein linearealgebraisch.

Optimierungsproblem

Finde $W, H \geq 0$, sodass:

$$\min_{W, H \geq 0} \|A - W \cdot H\|_F$$

wobei $\|\cdot\|_F$ die Frobenius-Norm ist (eine Maßzahl für den „Abstand“ zwischen zwei Matrizen).

Algorithmus: *Alternating Least Squares*. Halte W fest, optimiere H ; halte H fest, optimiere W . Iteriere.

Im Gegensatz zu LDA: *keine* probabilistische Interpretation. Aber: NMF ist *schneller*, *deterministischer* (gleicher Input $\rightarrow$ ähnlicher Output) und oft *stabiler* bei kleinen Korpora.

LDA vs. NMF – praktischer Vergleich

	LDA	NMF
Grundlage	Probabilistisches Modell	Lineare Algebra
Ausgabe	Wahrscheinlichkeiten	Gewichte (positiv)
Reproduzierbarkeit	Stochastisch – variiert je Lauf	Deterministisch bei festem Startwert
Geschwindigkeit	langsamer	schneller
Kleine Korpora	instabil	oft besser
Theoretische Schönheit	elegantes Bayessches Netzwerk	einfache Optimierung

In MTA: beide Verfahren sind verfügbar, und es wird empfohlen, sie zu *vergleichen*. Wenn sie ähnliche topics liefern, ist das ein Indiz für die Stabilität der Ergebnisse.

Wie viele topics? Die Modellselektion

Sowohl LDA als auch NMF setzen die Anzahl der topics K als **externen Parameter** voraus. *Wer entscheidet das?*

Drei Strategien:

1. **Perplexity / Likelihood** (LDA): Wie gut beschreibt das Modell *neue* Daten? Aber: nicht alle topics, die die Perplexity verbessern, sind *interpretierbar* (Chang et al. 2009).
2. **Kohärenz** (PMI, Newman et al. 2010): Wie oft tauchen die top-Wörter eines topics *nahe beieinander* im Korpus auf? Korreliert besser mit menschlicher Bewertung.
3. **Kreuzvalidierung mit Clusterverfahren** (in MTA implementiert): Elbow, Silhouette, Calinski-Harabasz, Davies-Bouldin, Cophenet. Das Programm schlägt Ihnen einen Wertebereich vor.

Keine dieser Methoden liefert *die eine* richtige Zahl. Die letzte Entscheidung bleibt *interpretativ*.

Ein Sprung in der Methodologie (seit 2018)

Das Buch von Papilloud & Hinneburg ist 2018 erschienen. Damals galten LDA und NMF als „state of the art“.

Seitdem hat sich Vieles verändert:

- 2013: **Word2Vec** (Mikolov et al.) – die Idee von *word embeddings*: jedes Wort als Punkt in einem hochdimensionalen Vektorraum.
- 2018-2019: **BERT** (Devlin et al.) – kontextuelle Embeddings: dasselbe Wort hat *verschiedene* Repräsentationen je nach Satz.
- 2022: **BERTopic** (Grootendorst) – ein Topic-Modell, das BERT-Embeddings nutzt.
- 2022 ff.: **ChatGPT, GPT-4, Claude, LLaMA ...** – Large Language Models. Sie können Texte *verstehen* und *annotieren*.

Was sind *Embeddings*?


Idee

Jedes Wort wird durch einen **Vektor** in einem hochdimensionalen Raum repräsentiert (z.B. 300 oder 768 Dimensionen). Wörter mit ähnlicher Bedeutung haben *ähnliche Vektoren*.

- Klassische TM (LDA/NMF) arbeiten mit *rohen Worthäufigkeiten*: „König“ und „Königin“ sind unverbunden.
- Embeddings codieren die *semantische Ähnlichkeit*:
 $\vec{v}(\text{König}) - \vec{v}(\text{Mann}) + \vec{v}(\text{Frau}) \approx \vec{v}(\text{Königin})$.
- Bei **BERT**: die Repräsentation hängt vom *Kontext* ab. „Bank“ im Satz „Sitzbank im Park“ ist nicht „Bank“ im Satz „Geld auf der Bank“.

Achtung: in MTA ist *Word2Vec* ebenfalls implementiert (Menü „Semantic Context“). Die Idee kommt also bereits in unserer Praxis vor.

BERTopic in einem Bild



Statt eine Matrix zu faktorisieren:

1. jeder Text wird zu einem *Vektor* (BERT),
2. Vektoren werden geclustert,
3. für jeden Cluster wird die Wortliste durch eine angepasste TF-IDF-Heuristik berechnet (*class-based TF-IDF*).

BERTopic vs. LDA/NMF – die Forschungslage

Empirische Vergleiche (Egger & Yu 2022; Kaur & Wallace 2024; Mishra 2026; Ma et al. 2025):

Wo BERTopic besser ist:

- Bei *kurzen* Texten (Tweets, SMS, Antworten auf offene Fragen).
- Bei semantisch *nuancierten* Domänen, wo Ko-Okkurrenz allein nicht reicht.
- Höhere *Topic-Kohärenz* in vielen Benchmarks.

Wo LDA/NMF kompetitiv bleiben:

- Bei *längeren* Texten (Artikel, Interviews, Bücher).
- Wenn *Interpretierbarkeit* und *Reproduzierbarkeit* wichtiger sind als Kohärenz allein.
- Bei *kleinen* Korpora – BERTopic verlangt oft sehr viele Dokumente und verwirft 30–70 % als *Outliers* (Soledad et al. 2022).
- Bei *spezialisierten* Sprachen oder Disziplinen, für die kein guter vortrainierter BERT verfügbar ist.

Large Language Models in der Textanalyse

Seit 2022 verändert sich das Feld noch einmal. LLMs (GPT-4, Claude, LLaMA) können:

- Transkripte **zusammenfassen** und thematisch annotieren.
- Texte direkt **codieren** – inklusive *deduktiver* Codierung anhand eines Codebuches (Tai et al. 2024).
- **Themen erzeugen** oder *labels* für vorhandene topics formulieren (TopicGPT, QualIT).
- *Reflexive Co-Researcher* sein: Memos schreiben, Codierungswidersprüche aufzeigen (Sinha et al. 2024).

Eine umfangreiche Literatur ist seit 2023 entstanden: Bail (2023), Hayes (2025), Than et al. (2025), Tai et al. (2024).

Aber: erste empirische Kritik

Ashwin, Chhabra & Rao (2025) – *Sociological Methods & Research*

Untersuchung von Interviews mit Rohingya-Geflüchteten und bengalischen Gastgebern.

Befund:

LLMs codieren *systematisch verzerrt*: ihre Fehler sind **nicht zufällig** verteilt, sondern korrelieren mit den Merkmalen der Befragten (Sprache, Bildung, Region).

Konsequenz: Inferenzen, die auf LLM-Codierungen beruhen, können *systematisch falsch* sein – in eine *bestimmte* Richtung.

Die Autoren empfehlen: lieber ein *eigenes, kleineres* Modell auf hochwertigen, manuell codierten Daten trainieren als einen generischen LLM einzusetzen.

Eine Erinnerung daran, dass auch „intelligente“ Maschinen keine neutralen Werkzeuge sind.

Warum bleibt MTA bei LDA und NMF?

Eine berechnete Frage. Die Antwort hat *vier* Aspekte:

1. **Lokal, offline, autonom.** MTA läuft auf Ihrem Laptop ohne Internetverbindung und ohne API-Schlüssel. Ihre Daten verlassen Ihre Maschine nicht.
2. **Interpretierbarkeit.** LDA und NMF liefern *nachvollziehbare* Wortlisten und Gewichte. Sie können erklären, warum ein topic so aussieht, wie es aussieht.
3. **Reproduzierbarkeit.** NMF mit festem Startwert produziert *exakt dieselben* Ergebnisse. LLMs nicht.
4. **Forschungsdidaktik.** Wer LDA/NMF versteht, versteht den *Kern* der Topic-Modellierung. Wer mit BERTopic anfängt, ohne Embeddings zu kennen, arbeitet mit einer Blackbox.

Was wir heute gesehen haben

1. Ein **topic** ist eine Gruppe von Wörtern, die oft gemeinsam vorkommen. Mathematisch: ein topic-Modell zerlegt die Dokument-Wort-Matrix in das Produkt zweier kleinerer Matrizen.
2. Topic-Modelle unterscheiden sich von Clusteranalysen (*mixed-membership*) und von Faktorenanalysen (*nicht-negativ*, andere Verteilungsannahmen).
3. **LDA** ist probabilistisch, **NMF** linearealgebraisch. Beide sind in MTA verfügbar und sollten *verglichen* werden.
4. **BERTopic** und **LLMs** sind die modernen Alternativen. Sie haben Stärken, aber auch ernsthafte methodologische Probleme. MTA bleibt aus guten Gründen bei LDA und NMF.

Ausblick auf Sitzung 3

Sitzung 3 – Vom Verfahren zur Interpretation

- Bevor der Algorithmus läuft: was ist ein *Dokument*? Was sind *Stoppwörter*? Wie reinigt man eine Textquelle?
- TF-IDF, Lemmatisierung, NER – und was MTA *nicht* tut.
- Metadaten und Topic-Modelle: drei Strategien.
- Der kritische Blick (Buch, Kap. 8): Was Topic-Modelle *nicht* können. Zwei Erwartungen, die nicht erfüllt werden.
- Was sich für unsere Forschungspraxis ändert – und wie diese drei Sitzungen in die folgende Arbeit mit MTA münden.

Zitierte Literatur (Auswahl) I

GRUNDLAGE:

Papilloud, C., & Hinneburg, A. (2018). *Einführung in die qualitative Analyse von Texten mit Topic-Modellen*. Wiesbaden: Springer. *Bes. Kap. 2 und 3*.

KLASSISCHE TOPIC-MODELLE:

- Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993–1022.
- Lee, D. D., & Seung, H. S. (2001). Algorithms for Non-Negative Matrix Factorization. *NIPS*.
- Griffiths, T. L., & Steyvers, M. (2004). Finding scientific topics. *PNAS*, 101(suppl. 1), 5228–5235.
- Newman, D., Lau, J. H., Grieser, K., & Baldwin, T. (2010). Automatic Evaluation of Topic Coherence. *NAACL HLT*.
- Chang, J., et al. (2009). Reading Tea Leaves: How Humans Interpret Topic Models. *NIPS*.

EMBEDDINGS UND BERT:

- Mikolov, T., et al. (2013). Efficient Estimation of Word Representations in Vector Space. *arXiv:1301.3781*.

Zitierte Literatur (Auswahl) II

- Devlin, J., et al. (2019). BERT: Pre-training of Deep Bidirectional Transformers. *NAACL HLT*.
- Grootendorst, M. (2022). BERTopic: Neural Topic Modeling with a Class-based TF-IDF Procedure. *arXiv:2203.05794*.
- Mostafavi, M., Porter, M. D., & Robinson, D. T. (2025). Contextual Embeddings in Sociological Research. *Sociological Methodology*.

EMPIRISCHE VERGLEICHE LDA/NMF/BERTOPIC:

- Egger, R., & Yu, J. (2022). A Topic Modeling Comparison Between LDA, NMF, Top2Vec, and BERTopic. *Frontiers in Sociology*.
- Kaur, A., & Wallace, J. R. (2024). Moving Beyond LDA: A Comparison of Unsupervised Topic Modelling Techniques. *arXiv:2412.14486*.
- Mishra, M. (2026). Comparative Analysis of BERTopic Versus LDA: Topic Modelling in Marketing Research. *Asia-Pacific Journal of Management Research*.
- Ma, L., et al. (2025). AI-powered topic modeling: comparing LDA and BERTopic. *Experimental Biology and Medicine*.

LLMS IN DER QUALITATIVEN SOZIALFORSCHUNG:

Zitierte Literatur (Auswahl) III

- Hayes, A. S. (2025). „Conversing“ With Qualitative Data: Enhancing Qualitative Research Through LLMs. *International Journal of Qualitative Methods*.
- Ashwin, J., Chhabra, A., & Rao, V. (2025). Using LLMs for Qualitative Analysis can Introduce Serious Bias. *Sociological Methods & Research*.
- Tai, R. H., et al. (2024). An Examination of the Use of Large Language Models to Aid Analysis of Textual Data. *International Journal of Qualitative Methods*.
- Than, N., Fan, L., Law, T., Nelson, L. K., & McCall, L. (2025). Updating „The Future of Coding“: Qualitative Coding with Generative Large Language Models. *Sociological Methods & Research*.
- De Paoli, S. (2023). Performing an Inductive Thematic Analysis of Semi-Structured Interviews With a Large Language Model. *Social Science Computer Review*.

Vielen Dank.

Fragen, Einwände, Anschlüsse?

christian.papilloud@soziologie.uni-halle.de