

Vom Verfahren zur Interpretation

Sitzung 3 – Vorverarbeitung, Metadaten
und ein kritischer Blick auf Topic-Modelle

Begleitendes Handout

Prof. Dr. Christian Papilloud

Institut für Soziologie – Martin-Luther-Universität Halle-Wittenberg

Master Soziologie – 2026

1. Worum es heute geht

In den ersten beiden Sitzungen haben wir Topic-Modelle (TM) *methodologisch* positioniert und *technisch* verstanden: quantitativ basiert, qualitativ einsetzbar, näher an Mayring als an Oevermann; vom Grundprinzip der Matrixfaktorisierung bis zu LDA, NMF, BERTopic und LLMs.

Die heutige Sitzung schließt den theoretischen Teil ab. Sie behandelt das, was zwischen *Forschungsfrage* und *Algorithmus* liegt – und das, was *nach* dem Algorithmus kommt. Vier Blöcke:

1. **Vor dem Algorithmus.** Was ist ein Dokument? Wie reinigt man eine Textquelle? Wie funktioniert der TF-IDF-Score?
2. **Metadaten.** Wie binden wir Variablen wie Zeit, Autor:in oder Quelle in die Analyse ein? Drei Strategien.
3. **Nach dem Algorithmus.** Der kritische Blick: zwei verbreitete Erwartungen, die Topic-Modelle *nicht* erfüllen können.
4. **Forschungspraxis.** Was sich für unsere Arbeit ändert. Übergang zur eigentlichen Praxis mit MTA.

Eine wichtige Botschaft vorab. Die wichtigste Operation eines Topic-Modell-Verfahrens findet nicht im Algorithmus statt, sondern *davor* (in der Vorbereitung der Daten) und *danach* (in der Interpretation). Der Algorithmus selbst ist relativ einfach. Was ein gutes von einem schlechten Topic-Modell unterscheidet, sind die Entscheidungen, die der/die Forschende um den Algorithmus herum trifft.

2. Was *vor* dem Algorithmus geschieht

2.1 Was ist ein *Dokument*?

Diese Frage klingt trivial. Sie ist es nicht. Bevor wir ein Topic-Modell rechnen können, müssen wir entscheiden, was *eine Beobachtungseinheit* ist.

Beispiele:

- Bei einer Sammlung von Zeitungsartikeln: jeder Artikel = ein Dokument? Oder jeder *Absatz* = ein Dokument? Die Wahl ändert das Ergebnis fundamental.
- Bei einem qualitativen Interview: das ganze Transkript = ein Dokument? Oder jede Antwort einzeln? Oder eine *Sequenz* zusammengehöriger Antworten?
- Bei einer Sammlung von Werken: jedes Buch = ein Dokument? Oder jedes Kapitel?

Die Wahl der *Dokumentgröße* ist eine **methodologische Entscheidung**, keine technische. Sie hängt von der Forschungsfrage ab. Zu *kleine* Dokumente führen dazu, dass die Maschine zu wenig Kontext für jedes „Dokument“ sieht. Zu *große* Dokumente führen dazu, dass mehrere Themen *in einem* Dokument vermischt werden und vom Modell nicht mehr unterschieden werden können.

2.2 Stoppwörter und Bereinigung

Topic-Modelle arbeiten auf *Wortbasis*. Die häufigsten Wörter einer Sprache (*der, die, das, und, aber*) tragen aber keine inhaltliche Information. Sie würden, *wenn man sie behält*, in allen topics oben erscheinen und die Ergebnisse unbrauchbar machen.

Stoppwörter sind diese semantisch leeren Wörter. Sie werden vor der Analyse entfernt. Listen sprachspezifischer Stoppwörter sind frei verfügbar (für Deutsch z. B. in MTA enthalten). Aber: **Sie können diese Liste an Ihr Korpus anpassen.** Wenn alle Ihre Dokumente das Wort *Universität* enthalten, weil sie alle aus einem Universitäts-Newsletter stammen, dann ist *Universität* funktional ein Stoppwort und gehört auf die Liste.

Weitere Reinigungsschritte:

- Zeichensetzung, Zahlen, Sonderzeichen entfernen.
- In transkribierten Interviews: „äh“, „hmmm“, „[lacht]“ usw. entfernen.
- Sehr seltene Wörter entfernen (z. B. Wörter, die in weniger als 2–3 Dokumenten vorkommen). Sie bringen Rauschen, keine Information.

2.3 TF-IDF – den „Wert“ messen

Wenn das Vokabular zu groß ist, ist es sinnvoll, nur die *aussagekräftigsten* Wörter zu behalten. Aber wie misst man *Aussagekraft*? Eine etablierte Heuristik: der **TF-IDF-Score**.

Idee. Ein Wort ist aussagekräftig, wenn:

- es *häufig genug* im Korpus vorkommt (sonst sehen wir es zu selten);
- aber *nicht in jedem* Dokument vorkommt (sonst trennt es keine Dokumente voneinander).

Formal: für jedes Wort i berechnet man die *Term Frequency* tf_i (wie oft das Wort vorkommt) und die *Inverse Document Frequency* $idf_i = \log_{10}(N/n_i)$, wobei N die Gesamtzahl der Dokumente ist und n_i die Anzahl der Dokumente, in denen das Wort vorkommt.

Beispiel aus dem Buch. Im Reuters-Korpus (806 791 Texte) haben die Wörter *Versuch* und *Versicherung* eine ähnliche Korpushäufigkeit (10 422 vs. 10 440). Aber *Versuch* steht in 8 760 Dokumenten, *Versicherung* nur in 3 997. Der IDF-Wert von *Versicherung* ist daher höher: das Wort ist auf wenige Dokumente *konzentriert* – ein Hinweis auf Aussagekraft.

2.4 Was MTA *nicht* tut: Lemmatisierung, NER, Phrasen

In der computer-linguistischen Forschung gibt es weitere Operationen der Vorverarbeitung, die für TM hilfreich sein *können*:

Lemmatisierung. Wörter werden auf ihre Grundform zurückgeführt: *ging, gingen, gegangen* → *gehen*; *Häuser, Hauses* → *Haus*. Reduziert das Vokabular und verbessert oft die topics. *Stemming* (ältere Variante) ist weniger empfehlenswert: es kürzt Wörter mechanisch und kann Bedeutungen verschmelzen.

Named Entity Recognition (NER). Erkennt Eigennamen (*Berlin, Merkel, FAZ*) und kann sie als zusammengesetzte „Wörter“ behandeln. Erhöht die inhaltliche Dichte der topics.

Phrasen. Wortgruppen, die oft zusammen vorkommen (*soziale Frage, Martin-Luther-Universität*), werden als *ein* Token behandelt. Inhaltlich oft präziser als die Einzelwörter.

In MTA werden diese Schritte nicht standardmäßig durchgeführt. Das ist eine bewusste Entscheidung: für die meisten qualitativen Analysen mit moderat großen Korpora sind sie nicht entscheidend, und sie würden die Installation des Programms deutlich komplizierter machen. Wenn Ihr Projekt sie verlangt, müssen Sie Ihre Texte *vor* der MTA-Analyse mit einem externen Tool vorbereiten (z. B. spaCy oder TreeTagger für Lemmatisierung).

3. Metadaten

Bisher haben wir Texte als *reine Wortansammlungen* behandelt. Aber unsere Dokumente haben in der Regel *Metadaten*: Datum, Autor:in, Quelle, Zielgruppe, Genre usw.

Es gibt **drei Strategien**, um diese Metadaten in eine Topic-Modell-Analyse einzubinden.

3.1 Strategie 1 – Spaltung

Idee. Das Korpus wird nach Metadatenwerten in Teilkorpora zerlegt. Man rechnet ein separates Topic-Modell für jede Teilmenge.

Beispiel. Sie haben 2000 Artikel: 1000 aus der FAZ, 1000 aus der taz. Sie rechnen zwei Topic-Modelle, eines pro Zeitung, und vergleichen sie.

Vorteil. Die topics können sich pro Gruppe *wirklich* unterscheiden – jede Gruppe bekommt ihre eigene Wortverteilung.

Nachteil. Die Topic-Listen sind nicht direkt vergleichbar. „Topic 3 bei FAZ“ und „Topic 3 bei taz“ sind zwei verschiedene Dinge, die manuell in Beziehung gesetzt werden müssen.

In MTA. Möglich: führen Sie MTA zweimal aus, einmal pro Teilkorpus.

3.2 Strategie 2 – Hinzufügung

Idee. Die Metadaten werden *nach* der Topic-Inferenz in die Analyse eingebunden. Man rechnet *ein* Topic-Modell auf dem gesamten Korpus und betrachtet dann, wie sich die Topic-Verteilungen *nach Gruppen* unterscheiden.

Beispiel. Sie rechnen 8 topics auf allen Migrations-Artikeln. Dann fragen Sie: kommt Topic 3 („Wirtschaftliche Aspekte“) bei der FAZ häufiger vor als bei der taz?

Vorteil. Flexibel und statistisch gut kontrollierbar. Man kann statistische Tests anwenden – in MTA z. B. den Welch-t-Test mit Benjamini-Hochberg-Korrektur (im Menü „Group Comparison“).

Nachteil. Die topics selbst sind *nicht* durch die Metadaten beeinflusst. Wenn die Metadaten die topics *strukturieren* sollten, geht das verloren.

3.3 Strategie 3 – Lernergänzung

Idee. Das Topic-Modell selbst wird so erweitert, dass die Metadaten *Teil der statistischen Modellierung* werden. Beispiele sind *Dynamic Topic Models* (Blei & Lafferty 2006) für Zeitserien oder *Author Topic Models* (Rosen-Zvi et al. 2004) für Autor:innen-Effekte.

Vorteil. Die strukturelle Wirkung der Metadaten wird direkt im Modell abgebildet.

Nachteil. Komplex zu implementieren, eingeschränkte Software-Verfügbarkeit, schwerer zu interpretieren.

In MTA nicht verfügbar. Die Empfehlung von Papilloud & Hinneburg (2018, S. 35): Strategie 2 (Hinzufügung) ist meistens vorzuziehen, wenn die Metadaten nicht zwingend strukturell modelliert werden müssen.

3.4 Synopse der drei Strategien

	Spaltung	Hinzufügung	Lernergänzung
Topic-Inhalt	kann pro Gruppe variieren	gemeinsam für alle Gruppen	strukturell beeinflusst
Interpretation	gruppenweise	vergleichend	vereinheitlicht
Statistische Tests	schwer möglich	ja (Welch, Mann-Whitney, BH)	im Modell integriert
Verfügbar in MTA	ja (per zwei Durchläufe)	ja (Group Comparison)	nein

4. Der kritische Blick: zwei falsche Erwartungen

Wir kommen zum Kapitel 8 des Buches (*Rück- und Ausblick*). Zwei verbreitete Erwartungen werden dort explizit zurückgewiesen. Beide werden Sie in der Literatur und in der Praxis immer wieder hören. Beide sind *falsch*.

4.1 Erwartung 1 – „Topic-Modelle überwinden die Unterscheidung quali/quant“

Das Argument lautet meistens: Da Topic-Modelle Statistik und Mathematik einsetzen, lösen sie das alte Paar *qualitativ vs. quantitativ* auf. Sie wären eine Art *Brücke* zwischen beiden Lagern.

Warum das nicht stimmt (Buch, S. 152):

- Topic-Modelle setzen die Arbeit an *Texten* voraus – also am *Sinn* von Begriffen und Sprachen.
- Diese Daten lassen sich nicht auf eine einzige Bedeutung reduzieren. Sie können nicht rein quantitativ interpretiert werden, „wie eine Variable“.
- Topic-Modelle reduzieren die Komplexität von Textquellen *nicht*. Sie sind *im Gegenteil* dazu gemacht, die *Multiperspektivität* einer Textquelle nicht zu reduzieren, sondern zu *strukturieren*.
- Statt die Komplexität eines Textes zu reduzieren, laden TM dazu ein, sie zu *erkennen* und zu *vertiefen*.

Pointe. Topic-Modelle können quantitative Verfahren *begleiten* (Mixed-Methods-Forschung). Aber sie sind nicht *a priori* „besser“ oder „neutraler“, weil sie mit Zahlen arbeiten. Wer dies behauptet, missversteht, was ein qualitatives Verfahren ist.

4.2 Erwartung 2 – „Topic-Modelle reduzieren die Interpretation auf ein Minimum“

Das Argument: Da der Algorithmus die Kategorien selbst findet, müssen wir nur noch die Ergebnisse „lesen“. Im Vergleich zu Oevermann oder Mayring soll TM eine Befreiung von der mühsamen Codierarbeit sein.

Warum das nicht stimmt (Buch, S. 152–153):

Die Ergebnisse eines Topic-Modells hängen *stark* ab von:

- der Forschungsfrage (was wir suchen);
- den theoretischen Rahmenannahmen;
- den Vorverarbeitungsentscheidungen (Stoppwörter, Dokumentgröße, Lemmatisierung);
- der Wahl der Anzahl topics K ;
- der Wahl von LDA oder NMF (und in der neuen Welt: BERTopic oder LLM);
- dem Korpus selbst und seinen Auswahlentscheidungen.

Konsequenz. Die topics sind *Hypothesen*, keine Befunde. Ihre Bedeutung muss durch *Lektüre* der besten Dokumente, durch *Vergleich* mit Theorie und durch *Diskussion* erarbeitet werden. Die menschliche Interpretationsarbeit verschwindet nicht; sie *verlagert sich*.

4.3 Pflichtlektüre: Schmidt 2012

Eine wichtige Referenz, die das Buch zitiert: **Benjamin Schmidt** (2012), der anhand historischer und geographischer Daten zeigt, wie Topic-Modelle zu *falschen Ergebnissen* führen können, wenn sie „blind“ angewendet werden.

Schmidts Forderung: Topic-Modelle in den Geistes- und Sozialwissenschaften müssen **mit Vorsicht und kritischer Reflexivität** eingesetzt werden. Konkret heißt das:

1. Topics nicht für bare Münze nehmen – immer mit den *besten Dokumenten* konfrontieren (welche Dokumente haben in diesem Topic das höchste Gewicht?).
2. Mehrere Modelle laufen lassen (verschiedene K , LDA und NMF) und Konsistenz prüfen.
3. Ergebnisse mit *unabhängigen* Quellen oder Kennzahlen vergleichen.
4. Die *theoretische Rahmung* der Analyse explizit machen.

5. Wo bleibt der/die Forschende?

Am Ende der ersten Sitzung haben wir eine Frage offen gelassen:

Eine Sozialwissenschaftlerin, die mit MTA arbeitet, codiert nicht selbst – sie liest die Codierung einer Maschine. Verschiebt das die Subjektivität der Interpretation, oder verlagert es sie nur an einen anderen Ort?

Die Antwort lautet jetzt: *ja, es verlagert sie*. Aber die Verlagerung hat zwei interessante Eigenschaften.

Sie wird sichtbar. Alle Vorverarbeitungs- und Modellierungsentscheidungen sind dokumentierbar: welche Stoppwörter, welche Dokumentgröße, welche K -Werte getestet wurden, welches Modell gewählt wurde, warum. Bei einer klassischen qualitativen Inhaltsanalyse sind diese Entscheidungen oft impliziter.

Sie wird prüfbar. Eine andere Forscherin kann die Analyse mit denselben Parametern *wiederholen* und prüfen, ob sie zu den gleichen topics kommt. Das ist eine Form von Reproduzierbarkeit, die qualitative Methoden traditionell schwer erreichen.

Diese beiden Eigenschaften sind *nicht trivial*. Aber sie ersetzen *nicht* die hermeneutische Arbeit am Material. Sie verändern nur die Bedingungen, unter denen diese Arbeit stattfindet.

6. Was sich an der Forschungspraxis ändert

Topic-Modelle verändern den *Umgang* mit Texten in der sozialwissenschaftlichen Forschung. Aus dem Buch (S. 153):

- Wir können Texte *nicht mehr nur sequentiell, sondern auch parallel* lesen. Statt Buch nach Buch oder Interview nach Interview durchzugehen, können wir Hunderte oder Tausende von Dokumenten gleichzeitig betrachten.
- Wir können *sehr große* Sammlungen berücksichtigen – ganze Werke einer Autorin, alle Interviews eines Projekts, alle Artikel zu einem Thema über zehn Jahre. Das verändert das Kriterium *dessen, was relevante Literatur zu einem Thema ist*.
- Wir bekommen einen *neuen Typ von Hypothesenproduktion*: Hypothesen, die wir ohne den maschinellen Blick auf die ganze Sammlung nicht hätten formulieren können.

Diese Veränderungen haben einen *Preis*: die Verlagerung der Subjektivität, die Notwendigkeit zur Dokumentation aller Schritte, die Verpflichtung zur kritischen Reflexion. Das Buch nennt das die „Veränderung der Forschungspraxis“ (S. 153) – und sie ist nicht reversibel.

7. Zusammenfassung der drei Sitzungen

Drei Sitzungen, drei Antworten auf drei Fragen:

1. **Wovon sind Topic-Modelle eine Methode?** Sie sind eine *qualitative* Methode der Sozialwissenschaften – aber näher an Mayrings qualitativer Inhaltsanalyse als an Oevermanns objektiver Hermeneutik. Sie teilen die drei Grundannahmen (Nicht-Zufälligkeit des Sinns, Strukturiertheit, Rolle der Deutung), unterscheiden sich aber im Begriff von „Algorithmus“ und in der Rolle der Kontextvariation.
2. **Wie funktionieren sie?** Durch Faktorisierung der Dokument-Wort-Matrix in zwei kleinere Matrizen. Die zwei klassischen Verfahren sind *LDA* (probabilistisch) und *NMF* (algebraisch). Sie gehören zur Familie der Mixed-Membership-Modelle. Neuere Verfahren (BERTopic, LLMs) ergänzen das Bild – aber sie ersetzen die klassischen Verfahren nicht, weder methodologisch noch praktisch.
3. **Was können sie nicht?** Sie überwinden nicht die Unterscheidung qualitativ/quantitativ; sie reduzieren nicht die Interpretationsarbeit; sie sind keine neutralen Werkzeuge. Die Hauptarbeit liegt *vor* dem Algorithmus (Vorverarbeitung) und *nach* ihm (Interpretation, kritische Reflexion).

Zum Mitnehmen für die Praxis. Wenn Sie in den nächsten Wochen mit MTA arbeiten, denken Sie an die drei Sitzungen zurück. Sie werden sehen, dass die Software Sie immer wieder zwingt, Entscheidungen zu treffen, die theoretisch motiviert sein müssen. Das ist kein Mangel der Software – das ist die Pointe der Methode.

Zitierte Literatur

GRUNDTEXT der Sitzung:

Papilloud, C., & Hinneburg, A. (2018). *Einführung in die qualitative Analyse von Texten mit Topic-Modellen*. Wiesbaden: Springer. *Bes. Kap. 2.5 (Vorverarbeitung), Kap. 2.5.5 (Metadaten), Kap. 8 (Rück- und Ausblick)*.

VORVERARBEITUNG UND TF-IDF:

Boyd-Graber, J., Mimno, D., & Newman, D. (2014). Care and Feeding of Topic Models. In: E. M. Airoldi et al. (Hrsg.), *Handbook of Mixed Membership Models and Their Applications*. CRC Press.

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge UP.

Salton, G., Wong, A., & Yang, C. S. (1975). A vector space model for automatic indexing. *Communications of the ACM* 18(11): 613–620.

Schofield, A., & Mimno, D. (2016). Comparing apples to apple: The effects of stemmers on topic models. *TACL* 4: 287–300.

METADATEN-MODELLE:

Blei, D. M., & Lafferty, J. D. (2006). Dynamic Topic Models. In: *ICML 2006*, 113–120.

Mimno, D., & McCallum, A. (2008). Topic models conditioned on arbitrary features with Dirichlet-multinomial regression. *UAI 2008*.

Roberts, M. E., Stewart, B. M., & Tingley, D. (2014). stm: R package for Structural Topic Models. *Journal of Statistical Software*.

Rosen-Zvi, M., et al. (2004). The author-topic model for authors and documents. *UAI 2004*.

KRITISCHE REFLEXION:

Mimno, D., & Blei, D. (2011). Bayesian Checking for Topic Models. *EMNLP 2011*.

Schmidt, B. M. (2012). Words alone: Dismantling topic models in the humanities. *Journal of Digital Humanities* 2(1).

Gelman, A., et al. (2013). *Bayesian Data Analysis*. Chapman & Hall/CRC.

ZUR VERTIEFUNG:

Mohr, J. W., & Bogdanov, P. (2013). Introduction – Topic models: What they are and why they matter. *Poetics* 41(6): 545–569.

DiMaggio, P., Nag, M., & Blei, D. (2013). Exploiting affinities between topic modeling and the sociological perspective on culture. *Poetics* 41(6): 570–606.