

Vom Verfahren zur Interpretation

Sitzung 3—Vorverarbeitung, Metadaten
und ein kritischer Blick auf Topic-Modelle

Prof. Dr. Christian Papilloud

Institut für Soziologie
Martin-Luther-Universität Halle-Wittenberg

Master Soziologie – 2026

Wo wir stehen

In den ersten beiden Sitzungen haben wir Topic-Modelle *methodologisch* positioniert und *technisch* verstanden.

Heute schließen wir den theoretischen Teil ab mit dem, was zwischen *Forschungsfrage* und *Algorithmus* liegt – und was *nach* dem Algorithmus folgt:

1. *Vor* dem Algorithmus: Was ist ein Dokument? Wie reinigt man eine Textquelle? Was ist TF-IDF?
2. Wie kann man *Metadaten* in eine Topic-Modell-Analyse einbinden? Drei Strategien.
3. *Nach* dem Algorithmus – der kritische Blick: Zwei verbreitete Erwartungen, die Topic-Modelle *nicht* erfüllen.
4. Was sich für unsere Forschungspraxis ändert. Übergang zur Praxis mit MTA.

Die unsichtbare Hauptarbeit

Eine Topic-Modell-Analyse besteht aus vier Phasen (Papilloud & Hinneburg 2018, Kap. 2.4):

1. **Datenvorverarbeitung** – der heutige Schwerpunkt
2. **Topic-Modell-Inferenz** – letzte Sitzung
3. **Evaluation**
4. **Interpretation**

Pointe

Die Vorverarbeitung ist der Schritt, der die meiste Zeit kostet – und der die größten methodologischen Konsequenzen hat. Wer schlecht vorverarbeitet, bekommt schlechte topics. Es gibt keinen Algorithmus, der diese Phase ersetzt.

Frage 1: Was ist ein Dokument?

Es klingt trivial, ist es aber nicht.

- Ein Interview = *ein* Dokument? Oder eine *Aussage* = ein Dokument?
- Eine ganze Tageszeitung = ein Dokument? Oder ein *Artikel*? Oder ein *Absatz*?
- Ein Buch = ein Dokument? Oder ein *Kapitel*? Oder eine *Seite*?

Diese Wahl ist *nicht* technisch. Sie ist eine *theoretische Wahl*: Auf welcher Ebene sehen Sie die Strukturen, die Sie suchen?

Beispiel: Wenn Sie tageszeitungsweise gruppieren, finden Sie topics, die ganze *Ausgaben* dominieren. Wenn Sie artikelweise gruppieren, finden Sie topics, die einzelne *Themen* ausmachen. Wenn Sie absatzweise gruppieren, finden Sie *rhetoische Muster*. Drei Analysen, drei *verschiedene* Befunde.

Frage 2: Welche Wörter zählen?

Nicht alle Wörter sind gleich nützlich für die Themenfindung. Zwei Gruppen werden meistens entfernt:

1. **Wenig aussagekräftige Wörter** (Stoppwörter): Artikel, Pronomen, Präpositionen, Hilfsverben.

ein, mein, er, sie, und, aber, ist, hat, durch, mit ...

Sehr häufig, semantisch arm.

2. **Sehr seltene Wörter**: Wörter, die nur in einem oder zwei Dokumenten vorkommen.

Sie können keinem topic stabil zugewiesen werden und *stören* die Inferenz statistisch.

In MTA: Sie laden eine Stoppwörterliste hoch (stopwords_de.txt, stopwords_en.txt, ...). Bei der Datenvorbereitung können Sie zusätzliche Wörter manuell ausschließen.

TF-IDF – eine zentrale Gewichtung

TF-IDF (Term Frequency – Inverse Document Frequency) gewichtet Wörter doppelt:

- **TF** – Häufigkeit eines Wortes *im Dokument*. Je öfter, desto wichtiger für dieses Dokument.
- **IDF** – inverse Häufigkeit *über die Dokumente*.

$$\text{idf}_i = \log_{10} \left(\frac{N}{n_i} \right)$$

mit N = Gesamtzahl der Dokumente, n_i = Anzahl der Dokumente, die das Wort i enthalten.

Wörter, die in *allen* Dokumenten vorkommen, bekommen einen niedrigen IDF-Wert.

Beispiel: im Reuters-Korpus (806.791 Texte) haben die Wörter *Versuch* und *Versicherung* ähnliche Gesamthäufigkeiten ($\sim 10\,400$). Aber *Versuch* kommt in 8.760 Dokumenten vor, *Versicherung* nur in 3.997. *Versicherung* ist also stärker konzentriert – höherer IDF-Wert – für die Topic-Analyse aussagekräftiger.

Lemmatisierung, NER, Phrasen – optionale Schritte

Drei sprachliche Operationen, die Topic-Modelle verbessern können:

- **Lemmatisierung.** Reduziert Wörter auf ihre Grundform: *lief, laufen, gelaufen* → *laufen*.
Vermeidet, dass dieselbe semantische Einheit über mehrere topics verteilt wird.
- **Named Entity Recognition (NER).** Erkennt Eigennamen und mehrwortige Ausdrücke:
Martin Luther University Halle-Wittenberg → ein Token statt fünf.
- **Wortphrasen.** Häufige Wortgruppen werden zu *einem* Token zusammengefasst.
battery life → *battery_life*.

In MTA: Stoppwörter und TF-IDF sind eingebaut. Lemmatisierung, NER und Phrasen *nicht* – sie können vorher durch externe Werkzeuge (TreeTagger, spaCy) angewendet werden, wenn nötig.

Eine wichtige Empfehlung: pro Sprache, pro Korpus

Aus dem Buch (Papilloud & Hinneburg 2018, S. 8 der Doc)

„Wenn Sie Dateien in verschiedenen Sprachen haben, legen Sie sie *nicht* in dasselbe Verzeichnis. Erstellen Sie so viele Verzeichnisse wie nötig, z.B. eines für Ihre französischen Dateien, eines für Ihre deutschen, eines für Ihre englischen.“

Diese Trennung gilt aber nicht nur für Sprachen. Sie gilt auch für:

- Verschiedene *Autoren* (wenn der Stil unterschiedlich ist),
- Verschiedene *Genres* (Interviews vs. Briefe vs. Berichte),
- Verschiedene *Zeitperioden* (wenn das Vokabular sich stark gewandelt hat).

Jede Mischung führt zu *vermischten* topics. Trennen, dann vergleichen.

Was sind Metadaten?

Metadaten = Informationen über die Dokumente, die nicht im Text enthalten sind:

- Zeit der Veröffentlichung,
- Autorin oder Autor,
- Geschlecht, Alter, Bildungsstand der Befragten,
- Quelle (Zeitung, Plattform, Region),
- Zitate, Genre, Sprache ...

Diese Informationen sind für die soziologische Interpretation *wertvoll*. Wie binden wir sie in eine Topic-Modell-Analyse ein?

Es gibt drei Strategien.

Strategie 1 — Spaltung

Idee: Man teilt das Korpus nach der Metadaten-Variable in Teilkorpora und führt für jedes eine separate Topic-Analyse durch.

Beispiel: Korpus aus 2.000 Zeitungsartikeln zu Migration, 2015–2020. Wir wollen die *zeitliche Entwicklung* sehen.

→ Wir machen sechs separate Analysen, eine pro Jahr, und vergleichen die topics.

Vorteil: einfach umzusetzen, sauber interpretierbar pro Teilgruppe.

Nachteil: jede Teilgruppe muss groß genug bleiben. Bei wenigen Dokumenten pro Jahr ist die Analyse instabil. Außerdem: man verliert die *gemeinsamen* topics über die Gruppen hinweg.

In MTA entspricht das: man legt mehrere Verzeichnisse an und analysiert sie nacheinander.

Strategie 2 — Hinzufügung

Idee: Die Metadaten werden *nach* der Topic-Inferenz in die Analyse eingebunden. Man rechnet *ein* Topic-Modell auf dem gesamten Korpus und betrachtet dann, wie sich die Topic-Verteilungen *nach Gruppen unterscheiden*.

Beispiel: Wir berechnen 8 topics auf allen Migrations-Artikeln. Dann fragen wir: kommt Topic 3 (Wirtschaftliche Aspekte) bei der FAZ häufiger vor als bei der taz?

Vorteil: flexibel, statistisch gut kontrollierbar (man kann statistische Tests anwenden, wie in MTA mit Welch + BH).

Nachteil: die topics selbst sind *nicht* durch die Metadaten beeinflusst. Wenn die Metadaten die topics *strukturieren*, geht das verloren.

In MTA entspricht das: „Group Comparison“-Menü (mit Welch-t-Test und Benjamini-Hochberg-Korrektur).

Idee: Die Metadaten werden *während* der Topic-Inferenz einbezogen. Das Topic-Modell selbst wird so erweitert, dass es die Metadaten als Teil seines Modells nutzt.

Beispiele aus der Literatur:

- *Dynamic Topic Models* (Blei & Lafferty 2006): topics, die sich über die Zeit verändern dürfen.
- *Author-Topic Models* (Rosen-Zvi et al. 2004): Autoren haben eigene Topic-Profile.
- *Structural Topic Model (STM)* (Roberts et al. 2014): Metadaten beeinflussen sowohl Topic-Verteilung als auch Topic-Inhalt.

Vorteil: elegant; topics werden *strukturell* mit Metadaten verbunden.

Nachteil: mathematisch komplex; spezialisierte Implementierungen nötig. *In MTA nicht implementiert.*

Welche Strategie wann?

	Spaltung	Hinzufügung	Lernergänzung
Voraussetzung	große Teilgruppen	gemeinsames Korpus	spezialisiertes Modell
Topic-Inhalt	kann pro Gruppe variieren	gemeinsam für alle Gruppen	strukturell beeinflusst
Interpretation	gruppenweise	vergleichend	vereinheitlicht
Statistische Tests	schwer möglich	ja (Welch, Mann-Whitney, BH)	im Modell integriert
Verfügbar in MTA	ja	ja	nein

Empfehlung des Buches (Papilloud & Hinneburg 2018, S. 35): Strategie 2 (Hinzufügung) ist meistens vorzuziehen, wenn die Metadaten nicht zwingend strukturell modelliert werden müssen.

Topic-Modelle haben Grenzen

Wir kommen zum Kapitel 8 des Buches – *Rück- und Ausblick*. Zwei verbreitete Erwartungen werden dort explizit zurückgewiesen. Beide werden Sie in der Literatur und in der Praxis immer wieder hören. Beide sind *falsch*.

- **Erwartung 1:** Topic-Modelle überwinden die Unterscheidung qualitativ / quantitativ.
- **Erwartung 2:** Topic-Modelle reduzieren die Interpretationsarbeit *auf ein Minimum*.

Wir nehmen beide Erwartungen kurz auseinander.

Erwartung 1 – „Quali/Quanti überwinden“

Das Argument lautet meistens: Da Topic-Modelle Statistik und Mathematik einsetzen, lösen sie das alte Paar *qualitativ vs. quantitativ* auf.

Warum das nicht stimmt (Buch, S. 152):

- Topic-Modelle setzen die Arbeit an *Texten* voraus – also am *Sinn* von Begriffen.
- Diese Daten lassen sich nicht auf eine einzige Bedeutung reduzieren. Sie können nicht rein quantitativ interpretiert werden.
- Topic-Modelle reduzieren die Komplexität von Textquellen *nicht* – im Gegenteil, sie laden dazu ein, *Multiperspektivität* zu erkennen.

Pointe

Topic-Modelle können quantitative Verfahren *begleiten* (Mixed-Methods-Forschung). Aber sie sind nicht *a priori* „besser“ oder „neutraler“, weil sie mit Zahlen arbeiten.

Erwartung 2 — „Interpretation auf ein Minimum reduzieren“

Das Argument: Da der Algorithmus die Kategorien selbst findet, müssen wir nur noch die Ergebnisse „lesen“.

Warum das nicht stimmt (Buch, S. 152–153):

- Die Ergebnisse eines Topic-Modells hängen *stark* ab von:
 - der Forschungsfrage (was wir suchen);
 - den theoretischen Rahmenannahmen;
 - den Vorverarbeitungsentscheidungen;
 - der Wahl von K ;
 - der Wahl von LDA oder NMF;
 - der Stoppwörterliste;
 - ...
- Die topics sind *Hypothesen*, keine Befunde.
- Die Bedeutung der topics muss durch Lektüre der besten Dokumente, durch Vergleich mit Theorie, durch Diskussion mit Kollegen *erarbeitet* werden.

Schmidt 2012 — die Kritik

Schmidt zeigt anhand historischer und geographischer Daten, wie Topic-Modelle zu *falschen Ergebnissen* führen können, wenn sie „blind“ angewendet werden.

Seine Forderung: Topic-Modelle in den Geistes- und Sozialwissenschaften müssen **mit Vorsicht und kritischer Reflexivität** angewendet werden.

Was heißt das konkret?

1. Topics nicht für bare Münze nehmen – immer mit den besten Dokumenten konfrontieren.
2. Mehrere Modelle laufen lassen (verschiedene K , LDA und NMF) und Konsistenz prüfen.
3. Ergebnisse mit unabhängigen Quellen vergleichen.
4. Die theoretische Rahmung explizit machen.

Wo bleibt der/die Forschende?

Frage vom Ende der ersten Sitzung

Eine Sozialwissenschaftlerin, die mit MTA arbeitet, codiert nicht selbst, sondern sie liest die Codierung einer Maschine. Verschiebt das die Subjektivität der Interpretation – oder verlagert es sie nur an einen anderen Ort?

Die Antwort lautet jetzt: *ja, es verlagert sie*. Aber:

- Die Verlagerung ist *sichtbarer*: alle Vorverarbeitungs- und Modellierungsentscheidungen sind dokumentierbar.
- Sie ist *prüfbar*: jede andere Forscherin kann die Analyse mit denselben Parametern wiederholen.
- Sie ist *kommunizierbar*: man kann mit Kollegen über Parameter streiten, was bei rein interpretativen Verfahren schwerer ist.

Die Subjektivität verschwindet nicht. Sie wird transparenter.

Eine andere Art zu lesen

Das vielleicht wichtigste, was Topic-Modelle in die qualitative Forschung einbringen, ist eine *neue Lesepraxis*:

Buch, S. 153

Topic-Modelle erlauben, Texte nicht mehr nur *sequenziell* zu lesen, sondern sie auch *parallel* zu berücksichtigen.

Die klassische qualitative Forschung liest Texte einzeln, sequenziell, hermeneutisch. Topic-Modelle erlauben:

- parallele Sicht auf Hunderte oder Tausende von Texten,
- *Navigation* im Korpus über die topics,
- *vergleichende* Lektüre der besten Dokumente pro topic,
- Erkundung der *semantischen Nachbarschaften* von Begriffen.

Das ist nicht der *Ersatz* qualitativer Lektüre. Es ist ihr *Vorlauf* – eine Strukturierung, die das eigentliche Lesen vorbereitet.

Konsequenzen für die Forschungspraxis

Wer mit Topic-Modellen arbeitet, ändert eine Reihe von Praktiken:

- **Korpusgröße:** Hunderte oder Tausende von Texten werden zugänglich. Was „relevante Literatur“ ist, wird neu definiert.
- **Forschungsfrage:** sie muss explizit *operationalisiert* werden – in Form von Vorverarbeitungsentscheidungen und Parameterwahl.
- **Kooperation:** weil Parameter dokumentiert werden, können andere die Analyse *reproduzieren*, *kritisieren*, *weiterentwickeln*.
- **Wissenschaftliche Schreibweise:** man schreibt über *Verfahren*, nicht nur über *Befunde*. Methodenkapitel werden länger.

Was wir gelernt haben – Bilanz der drei Sitzungen

- 1. Sitzung 1:** Topic-Modelle gehören zu den qualitativen Methoden – sie teilen mit objektiver Hermeneutik und qualitativer Inhaltsanalyse drei Grundannahmen, aber sie unterscheiden sich in dem, was bei ihnen *algorithmisch* ist.
- 2. Sitzung 2:** Mathematisch sind sie eine *Matrixfaktorisierung* mit *Mixed-Membership*. LDA und NMF sind zwei Wege zum gleichen Ziel. BERTopic und LLMs sind moderne Alternativen mit Vor- und Nachteilen. MTA bleibt aus guten Gründen bei LDA und NMF.
- 3. Heute, Sitzung 3:** Der Algorithmus ist nur die *Mitte* einer Topic-Modell-Analyse. Vorverarbeitung und Interpretation machen den *Großteil* der Arbeit aus – und tragen die größte Verantwortung.

Übergang zur Praxis

Ab der nächsten Sitzung beginnen wir die praktische Arbeit mit MTA.

Was Sie für die erste Praxis-Sitzung mitbringen sollten:

- Ein kleines eigenes Korpus von Texten (5–20 Dateien) als .txt (UTF-8).
Beispiele: Zeitungsartikel zu einem Thema, das Sie interessiert; ein paar Interviewtranskripte aus einem früheren Projekt; offene Antworten aus einer Umfrage.
- Eine Frage, die Sie an diesen Texten stellen würden.
- MTA bereits auf Ihrem Laptop installiert (Installationsanleitung auf GitHub).

Erinnerung

Die theoretischen Grundlagen, die wir besprochen haben, sind *nicht* optional. Sie sind die Grundlage, auf der jede Topic-Modell-Analyse sinnvoll wird.

Zitierte Literatur I

GRUNDLAGE:

Papilloud, C., & Hinneburg, A. (2018). *Einführung in die qualitative Analyse von Texten mit Topic-Modellen*. Wiesbaden: Springer. *Bes. Kap. 2.5 und Kap. 8.*

VORVERARBEITUNG VON TEXTQUELLEN:

- Boyd-Graber, J., Mimno, D., & Newman, D. (2014). Care and Feeding of Topic Models. In E. M. Airoldi et al. (Hrsg.), *Handbook of Mixed Membership Models*. CRC Press.
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge UP. (TF-IDF, Kap. 6.2)
- Mimno, D. (2015). Optimizing Semantic Coherence in Topic Models. *EMNLP*.
- Schofield, A., & Mimno, D. (2016). Comparing Apples to Apple: The Effects of Stemmers on Topic Models. *TACL*.

METADATEN UND ERWEITERTE TOPIC-MODELLE:

- Blei, D. M., & Lafferty, J. D. (2006). Dynamic Topic Models. *ICML*.
- Roberts, M. E., et al. (2014). Structural Topic Models for Open-Ended Survey Responses. *American Journal of Political Science*, 58(4), 1064–1082.

Zitierte Literatur II

- Rosen-Zvi, M., Griffiths, T., Steyvers, M., & Smyth, P. (2004). The Author-Topic Model for Authors and Documents. *UAI*.
- Mimno, D., & McCallum, A. (2008). Topic Models Conditioned on Arbitrary Features with Dirichlet-Multinomial Regression. *UAI*.

KRITISCHE REFLEXION:

- Blei, D. M. (2013). Topic Modeling and Digital Humanities. *Journal of Digital Humanities*, 2(1).
- Gelman, A., Hennig, C., et al. (2013). Comment on „Hierarchical“ Models in the Social Sciences.
- Mimno, D., & Blei, D. (2011). Bayesian Checking for Topic Models. *EMNLP*.
- Schmidt, B. M. (2012). Words Alone: Dismantling Topic Models in the Humanities. *Journal of Digital Humanities*, 2(1).

Ende des theoretischen Teils.

Ab der nächsten Sitzung: Praxis mit MTA.

christian.papilloud@soziologie.uni-halle.de